

高教社杯全国大学生数学建模竞赛

承 诺 书

我们仔细阅读了中国大学生数学建模竞赛的竞赛规则。

我们完全明白，在竞赛开始后参赛队员不能以任何方式（包括电话、电子邮件、网上咨询等）与队外的任何人（包括指导教师）研究、讨论与赛题有关的问题。

我们知道，抄袭别人的成果是违反竞赛规则的，如果引用别人的成果或其他公开的资料（包括网上查到的资料），必须按照规定的参考文献的表述方式在正文引用处和参考文献中明确列出。

我们郑重承诺，严格遵守竞赛规则，以保证竞赛的公正、公平性。如有违反竞赛规则的行为，我们将受到严肃处理。

我们参赛选择的题号是（从 A/B/C/D 中选择一项填写）：_____

我们的参赛报名号为（如果赛区设置报名号的话）：_____

所属学校（请填写完整的全名）：_____

参赛队员（打印并签名）：1. _____

2. _____

3. _____

指导教师或指导教师组负责人（打印并签名）：_____

日期：_____年____月____日

赛区评阅编号（由赛区组委会评阅前进行编号）：

2010 高教社杯全国大学生数学建模竞赛

编号专用页

赛区评阅编号（由赛区组委会评阅前进行编号）：

赛区评阅记录（可供赛区评阅时使用）：

[illegible]

基于需求响应预测与组合优化的蔬菜类商品定价补货策略研究

摘要

生鲜蔬菜具有保鲜期短、需求波动大和损耗率高等特点，商超需要在批发价格尚未完全确定的情况下制定补货与定价方案。针对蔬菜类商品的销售规律分析、品类补货定价、单品组合优化及数据改进问题，本文基于某商超 2020 年 7 月 1 日至 2023 年 6 月 30 日的销售流水、批发价格和损耗率数据，构建“销量规律识别—需求响应预测—收益优化决策”的递进式模型体系。

针对问题一，采用**描述性统计**、**Spearman 秩相关**、**滞后相关**和**K-means 聚类模型**，首先分析六大蔬菜品类及单品销量的均值、波动性、偏度和零销售比例，其次识别品类间的同步关联与需求传导关系，最后根据销量、价格和损耗等特征对单品进行分类。结果表明，花菜类与食用菌呈较强正相关（ $\rho=0.474$ ），花叶类与辣椒类呈弱正相关（ $\rho=0.265$ ），茄类与水生根茎类呈弱负相关（ $\rho=-0.160$ ）；246 个单品被划分为 5 类，为后续候选单品筛选提供依据。

针对问题二，采用**加权平均**、**SARIMAX 时序预测**、**LASSO 回归**和**线性规划模型**，先将单品批发价格加权汇总至品类层面，再预测 2023 年 7 月 1 日至 7 日的批发价格，随后以加成率、星期类型、季节因素及关联品类滞后销量为变量建立需求响应函数，最后以 7 天总收益最大化为目标求解各品类的补货量和加成率。结果显示，模型交叉验证 MAPE 为 **16.47%**，各品类拟合优度 R^2 为 **0.519 — 0.563**，7 天累计预测收益为 **8257.81 元**。

针对问题三，采用**需求比例分摊模型**、**混合整数线性规划模型**和 **ϵ -约束法**，先按照近期销量比例将品类需求分摊至单品层面，再将加成率离散化，并设置上架数量、最小陈列量和需求满足率等约束，求解单品的上架、补货和定价方案。结果表明，当 $\epsilon=0.85$ 时，推荐上架 31 个单品，预测收益为 **815.24 元**，需求满足率为 **95.18%**，各单品补货量均不低于 2.5 kg。

针对问题四，采用**扩展 LASSO 回归**和**扩展混合整数线性规划模型**，从气象因素、竞品价格、消费者购买记录和商品生命周期等方面补充数据，并分析其对需求预测、定价和选品决策的影响。结果表明，补充外部信息能够完善需求函数和候选单品筛选机制，为提高预测精度和优化商超经营策略提供改进方向。

关键词：生鲜蔬菜；补货定价；Spearman 秩相关；LASSO 回归；混合整数线性规划； ϵ -约束法

AI 工具使用说明：

本参赛队在竞赛过程中使用了 A 工工具，主要用于语言润色、表述规范化与 Python 代码调试辅助，详细使用情况见支撑材料“ AI 工具使用详情.pdf ”。

一、问题重述

随着居民生活水平的持续提升和健康饮食观念的广泛普及，新鲜蔬菜已成为超市生鲜品类中消费频率最高、需求量最大的商品之一。生鲜蔬菜具有保鲜期短、品相随销售时间增加而快速衰减的显著特征，大部分品种若当日未能售出，隔日便丧失商品价值，由此产生的损耗成为制约商超盈利能力的关键瓶颈。与此同时，蔬菜品类繁多、产地各异，进货交易通常安排在凌晨 3:00 至 4:00 进行^[2]，商家须在批发价格尚未公布、具体单品供应情况不完全明确的条件下，完成当日各蔬菜品类的补货与定价决策。这种“先决策、后知价”的时序错位，使得单纯依赖经验的补货方式难以实现收益最优。

从需求侧看，蔬菜的销售量与星期类型、季节变化、节气更替等因素存在显著关联；从供给侧看，每年 4 月至 10 月蔬菜供应品类丰富，但商超有限的销售空间使得合理的品种组合选择变得尤为关键。已有研究表明，采用成本加成定价模式的生鲜商超，其利润水平高度依赖于定价与补货的协同优化——单方面追求高加成率可能导致需求萎缩与损耗攀升，单方面扩大补货量则可能加剧库存积压与资源浪费。

在此背景下，本文基于某商超 2020 年 7 月 1 日至 2023 年 6 月 30 日的销售流水、商品品类映射、批发价格及损耗率等多源数据，系统研究以下四个子问题：

问题一旨在揭示蔬菜各品类及单品销售量的分布规律与内在关联。通过统计刻画、相关性分析与聚类挖掘，厘清品类间的协同与替代关系，为后续需求建模提供先验特征。

问题二以品类为决策单元，探究销售总量与成本加成定价之间的量化关系，在收益最大化目标下求解 2023 年 7 月 1 日至 7 日各品类的日补货总量与最优加成率。

问题三将决策粒度细化至单品层面，在可售单品总数 27 至 33 个、单品最小陈列量 2.5 千克的双重约束下，以 2023 年 6 月 24 日至 30 日的可售品种为候选集合，求解 7 月 1 日各单品的补货量与定价方案^[3]。

问题四从数据驱动的视角出发，识别现有数据体系的不足，提出对制定补货与定价决策具有实际价值的补充数据采集建议。

上述四个问题相互衔接、层层递进，构成“规律发现→品类决策→单品优化→策略升级”的完整研究链条，为生鲜商超在不确定环境下实现数据驱动的智慧运营提供系统性方法支撑。

二、 问题分析

问题一分析：本问核心难点是蔬菜销量存在零膨胀、右偏分布特征，传统基于正态假设的 Pearson 相关易产生偏差，同时不仅要定性判断商品是否共同销售，还需量化销量之间的关联强弱。本文采用统计刻画相关性分析聚类挖掘三层研究框架^[9]：通过偏度、零销售比例等指标刻画分布形态；选用对异常值稳健、无需正态假设的 Spearman 秩相关识别品类互补替代关系，并借助滞后相关挖掘跨品类需求传导的时滞效应；利用 Kmeans 聚类完成单品分类，筛选低动销高损耗单品。主要流程：①统计六大品类销量统计指标，判别分布特征；② Spearman 相关分析并显著性检验，识别品类协同、替代关系；③计算 13 天滞后交叉相关，确定最优滞后天数；④标准化单品多维度特征，基于轮廓系数确定 Kmeans 最优聚类数；⑤输出聚类结果供问题三筛选候选单品，输出相关、滞后特征供给问题二构建需求函数。

问题二分析：本问的现实矛盾在于商超凌晨进货时无法获知当日批发价格，加成率与补货量相互耦合：定价过高加剧损耗，定价过低压缩利润，需要在信息不完备下实现二者联合优化。整体按照时序预测需求建模优化求解开展研究：先预测未来 7 天批发价格，再建立销量对加成率的需求响应函数，最后以收益最大为目标求解决策变量。主要流程：①将单品批发价格按销量加权聚合得到品类批发价；② SARIMAX 模型预测 7 月 17 日品类批发价格，捕捉序列趋势与周度周期；③构建 LASSO 回归需求函数，引入问题一输出的关联滞后特征，依靠 L1 正则完成特征筛选、降低离群值干扰；④构建线性规划模型，在多重约束下求解各品类每日最优补货量与加成率；⑤输出 7 月 1 日品类需求上限，作为问题三的输入约束。

问题三分析：本问面临大规模候选集筛选难题，需要在 2733 个上架单品、2.5kg 最小陈列量的硬性约束下，权衡**收益最大化与需求满足率最大化**这一组相互冲突的目标，二者存在帕累托权衡关系。采用**候选筛选需求估计价格离散多目标优化**的技术路线：精简候选单品池，分摊得到单品层面需求；对加成率进行档位离散化，消解模型非线性；使用 ϵ 约束法处理双目标，规避主观权重赋值，求解得到帕累托最优解集。主要流程：①以 6 月 2430 日在售单品为初始候选集，剔除问题一得到的低动销高损耗单品；②依托问题二品类需求上限，按历史销量占比分摊估算单品需求；③离散化加成率档位，引入 01 变量实现模型线性化；④遍历 ϵ 参数求解 MILP 模型，绘制帕累托前沿；⑤选取拐点方案，输出各单品上架状态、补货量、加成率与售价。

问题四分析前三问建模受原始数据集限制，缺少气象、竞品价格、消费者偏好等关键信息，限制了需求预测精度与决策精细化程度。本文按照**识别数据缺口提出采集方案论证应用价值**的思路，从需求预测、市场竞争、供应链管理维度给出补充数据采集建议，阐明各类新增数据对改进需求函数、优化定价策略、提升选品前瞻性的实际作用。

文章思路图如图 1所示：

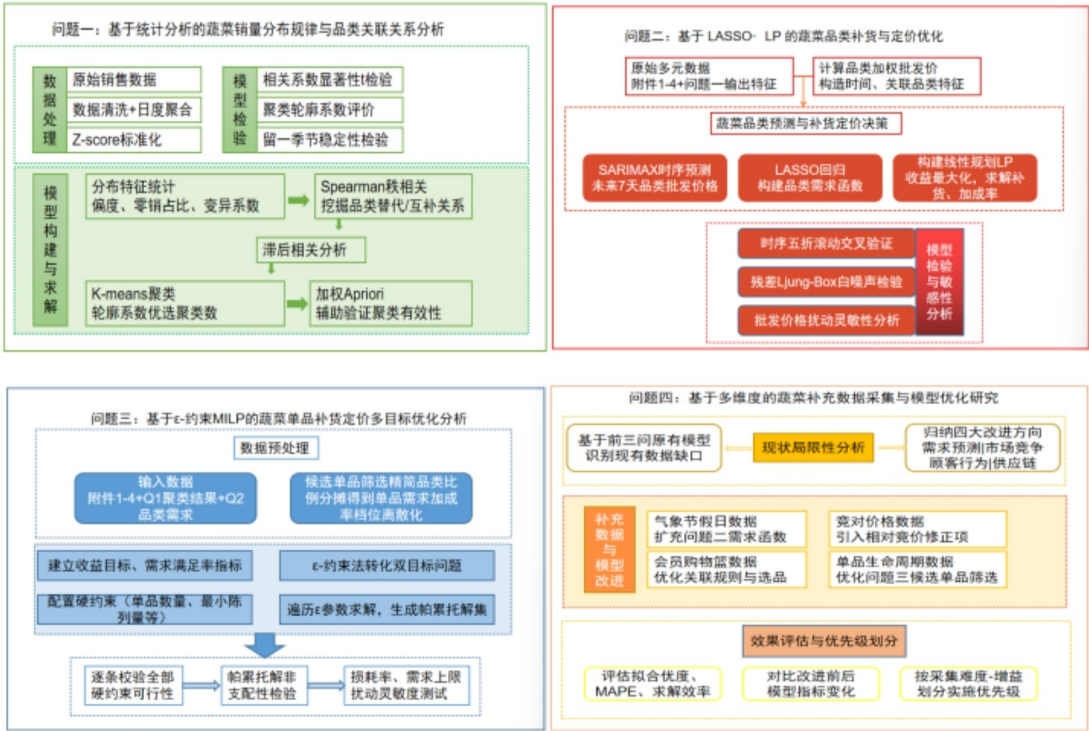


图 1四个问题建模流程

三、 模型假设

假设 1：单品日销量为零视为当日无销售；极少数缺货记录不进行插补；候选单品严格限定为 2023 年 6 月 24 日至 30 日有销售记录的单品。

假设 2：7 天短期之内品类损耗率保持稳定，使用附件 4 给出的近期损耗率；同一品类内各单品损耗率差异在汇总至品类层面时取销量加权平均值。

假设 3：商超采用成本加成定价模式，加成率在 $[0.10,0.80]$ 区间内可自由调整。

假设 4：当日未售出蔬菜全部报废、无残值；缺货仅损失对应毛利，不考虑长期客户流失。

假设 5：7 天短期之内品类需求函数保持稳定，忽略极端突发事件的影响。

四、 符号说明

名称	单位	含义
$X_{i,t}$	kg	单品 i 第 t 日销售量
$X_{m,t}$	kg	第 m 个品类第 t 日总日销量，该品类下全部单品日销量聚合
S_i	kg	单品 i 日销售量标准差
CV_i	-	单品 i 销量变异系数
$Skew_i$	-	单品 i 销量序列偏度系数
Z_i	-	单品 i 零销售比例
$R_{a,b}$	-	品类 a 与品类 b 的 Spearman 秩相关系数
W-Supp、W-Conf	-	加权 Aprior 算法的加权支持度、加权置信区间
$D_{m,t}$	kg	品类 m 第 t 日市场预测需求量
$S_{m,t}$	kg	品类 m 第 t 日实际可销售数量
TR_t	元	商超第 t 日全部品类总收益

五、 模型建立

5.1 蔬菜品类或单品销量分布规律及关联程度

5.1.1 数据描述统计分析

从集中趋势、离散程度、分布形态、零散销售占比四个维度^[9]刻画销售序列统计特征，为后续求解提供统计数据。

设单品 i 在统计期内共 T 个销售日，日销量序列为 $\{s_{i,t}\}_{t=1}^T$ （无销售记录时 $s_{i,t} = 0$ ）。定义以下统计量：

平均日销量 $\bar{s}_i = \frac{1}{T} \sum_{t=1}^T s_{i,t}$ ，反映单品或品类的整体销量水平。

标准差 $\sigma_i = \sqrt{\frac{1}{T-1} \sum_{t=1}^T (s_{i,t} - \bar{s}_i)^2}$ ，衡量销量的绝对波动程度。

变异系数 $CV_i = \sigma_i / \bar{s}_i$ ($\bar{s}_i > 0$) , 衡量销量的相对波动程度, 便于不同销量量级之间的比较。

偏度系数是衡量分布不对称性的核心指标, 其计算公式为:

$$Skew_i = \frac{\frac{1}{T} \sum_{t=1}^T (s_{i,t} - \bar{s}_i)^3}{\left[\frac{1}{T-1} \sum_{t=1}^T (s_{i,t} - \bar{s}_i)^2 \right]^{3/2}}$$

零销售比例:

$$Zero_i = \frac{1}{T} \sum_{t=1}^T \mathbf{1}_{\{s_{i,t}=0\}}$$

5.1.2 品类间 Spearman 秩相关系数

为刻画品类间日销量的同步变动关系, 需计算销量序列相关性。因销量数据非正态且存在大量离群值, Spearman 秩相关系数^[5]基于数据排序后的秩次计算, 无需满足正态假设, 可削弱异常值影响, 稳健衡量变量间单调同步关系。

将品类 a 和品类 b 的日销量序列 $\{S_{a,t}\}_{t=1}^T$ 和 $\{S_{b,t}\}_{t=1}^T$ 分别转换为秩次 $R(S_{a,t})$ 和 $R(S_{b,t})$ 。若 $S_{a,t}$ 是第 t 日所有销量中的最小值, 则 $R(S_{a,t})=1$; 若为最大值, 则 $R(S_{a,t})=T$ 。记 $d_t = R(S_{a,t}) - R(S_{b,t})$ 为第 t 日两品类销量秩次之差, Spearman 相关系数的简化计算公式为:

$$\rho_{ab} = 1 - \frac{6 \sum_{t=1}^T d_t^2}{T(T^2 - 1)}.$$

$\rho_{ab} > 0$ 表明两品类销量呈同向变化趋势, 可能具有互补或协同关系; $\rho_{ab} < 0$ 表明呈反向变化趋势, 可能存在替代关系。

为判断观察到的相关系数是否具有统计显著性, 构造 t 统计量:

$$t = \rho_{ab} \sqrt{\frac{T-2}{1-\rho_{ab}^2}} \sim t(T-2),$$

Spearman 相关仅能衡量同日销量同步关联, 而品类需求影响往往存在时滞: 消费者可能先后跨期购买不同品类, 产生需求传导效应。滞后相关分析计算某品类提前 k 天销量与另一品类当期销量的相关性, 用以识别领先-滞后关系。若品类 b 滞后 k 期与品类 a 当期销量相关性较高, 表明品类 b 的需求变动可作为品类 a 未来需求的预测信号,

可为问题二需求函数的滞后特征筛选提供依据。

计算滞后 k 天的交叉 Spearman 相关系数：

$$\rho_{ab}^{(k)} = \text{corr}(R(S_{a,t}), R(S_{b,t-k})),$$

其中 $R(S_{b,t-k})$ 为品类 b 在 t-k 日销量的秩次。

$\rho_{ab}^{(k)} > 0$ 表示品类 b 提前 k 天的销量变化与品类 a 当日的销量变化呈同向关系，即品类 b 领先于品类 a。取 $\rho_{ab}^{(k)}$ 达到最大值时的 k 作为最优滞后天数。

5.1.3 单品聚类分析

单品聚类通过将具有相似销量特征、价格特征和损耗特征的单品归为同一类别，实现单品类型的自动划分。计算单品之间在多个特征维度上的距离，距离近的归为一类，距离远的归为不同类

从单品层面提取 6 个特征：

$$\mathbf{x}_i = (\bar{s}_i, \sigma_i, Zero_i, \bar{P}_i^{sale}, \bar{r}_i, \delta_i),$$

上述特征涵盖销量规模、波动性、动销率、定价水平和损耗程度五个维度，能够全面刻画单品的经营价值与风险特征。由于各特征量纲不同（销量的量纲为 kg、价格量纲为元/kg、损耗率为百分比），直接使用原始数值计算欧氏距离会导致量纲大的特征主导距离度量。因此，需对每个特征进行 Z-score 标准化：

$$X_{i,j}^{(std)} = \frac{X_{i,j} - \mu_j}{\sigma_j},$$

其中 μ_j 和 σ_j 分别为第 j 个特征的均值和标准差。标准化后各特征均值为 0、标准差为 1，在距离计算中具有同等权重。

K-means 算法的优化目标为最小化簇内平方和：

$$\min_{C_1, \dots, C_K} \sum_{k=1}^K \sum_{i \in C_k} \|\mathbf{x}_i - \boldsymbol{\mu}_k\|^2,$$

其中 $\boldsymbol{\mu}_k$ 为第 k 簇的质心。

该目标函数的含义是：每个样本到其所属簇质心的距离平方和越小，说明簇内样本越紧密、聚类效果越好。

最优聚类数 K 通过轮廓系数确定：

$$Silhouette = \frac{1}{N} \sum_{i=1}^N \frac{b(i) - a(i)}{\max\{a(i), b(i)\}},$$

其中 $a(i)$ 为样本 i 到同簇其他样本的平均距离（簇内不相似度）， $b(i)$ 为样本 i 到其他各簇的最小平均距离（簇间不相似度）。轮廓系数取值范围为 $[-1,1]$ ，越接近 1 表示聚类效果越好。

采用 Aprior 检验^[1]，将每日销售记录聚合为事务 T_d ，单品 j 在事务中的权重 $w_{j,d} = q_{j,d} / \sum_{k \in T_d} q_{k,d}$ 。加权支持度与加权置信度的计算公式为：

$$Sup_w(X) = \frac{1}{D} \sum_{d=1}^D \left[\left(\prod_{j \in X} w_{j,d} \right) \cdot \mathbf{1}_{\{X \subseteq T_d\}} \right],$$

$$Conf_w(X \Rightarrow Y) = \frac{Sup_w(X \cup Y)}{Sup_w(X)}, \quad Lift(X \Rightarrow Y) = \frac{Conf_w(X \Rightarrow Y)}{Sup_w(Y)}.$$

若同类单品之间的强关联规则数量显著高于不同类单品之间的规则数量，则说明聚类结果不仅反映了特征相似性，也反映了实际的销售协同性，增强了聚类结论的说服力。

5.2 蔬菜品类补货与定价决策

5.2.1 品类加权平均批发价格计算

附件 3 提供的是单品级别的日度批发价格，而本问以品类为单位进行补货与定价决策，因此需要将单品批发价格按销量加权汇总至品类层面。加权平均的逻辑基于贡献度原则：销量越大的单品，其批发价格对品类整体成本的影响越大，应赋予更高的权重。品类 c 在 t 日的加权平均批发价格为：

$$p_{c,t}^{wholesale} = \frac{\sum_{j \in c} q_{j,t} \cdot p_{j,t}^{wholesale}}{\sum_{j \in c} q_{j,t}},$$

其中 $p_{j,t}^{wholesale}$ 为单品 j 在 t 日的批发价格（元/kg）， $q_{j,t}$ 为单品 j 在 t 日的销量（kg）。分母为该品类当日的总销量，确保权重之和为 1，使得 $p_{c,t}^{wholesale}$ 代表品类层面的单位成本水平。

5.2.2 批发价格预测

商超在凌晨 3:00-4:00 进行进货交易时，当日的批发价格尚未公布，因此需基于历史批发价格数据对未来 7 天的品类加权平均批发价格进行时序预测。批发价格序列具有典型的时序特征：趋势性（价格随季节缓慢变化）、周期性（每周 7 天的周期波动）和随机性（受天气、供需等偶然因素影响）。

SARIMAX 模型^{[4][7]}通过差分消除序列趋势与季节性，再对平稳序列构建自回归移动平均模型。原始价格序列 P_t 经 d 阶普通差分与周期为 s 的 D 阶季节差分得到平稳序列 W_t ， W_t 服从 ARMA 形式，当期值由历史 p 期观测与 q 期随机冲击线性组合得到。季节差分算子 $(1-B^s)^D$ 是其相较于 ARIMA 的核心差异，可剔除 7 天等固定周期波动，更适配蔬菜价格的周度周期特征。

SARIMAX 模型的数学表达式为：

$$\phi(B)\Phi(B^s)(1-B)^d(1-B^s)^D P_{c,t} = \theta(B)\Theta(B^s)\varepsilon_t,$$

其中 B 为滞后算子 ($BP_t = P_{t-1}$)， d 和 D 分别为非季节性和季节性差分阶数，

模型阶数 $(p, d, q)(P, D, Q)_s$ 通过 AIC 准则在 $p, q, P, Q \in [0, 2]$ 范围内网格搜索选取， $AIC = -2\ln L + 2k$ (L 为似然函数值， k 为参数个数)，在拟合精度与模型复杂度之间取得平衡。

作为对比，同时采用 Holt-Winters 三参数指数平滑模型对批发价格进行预测，以验证 SARIMAX 预测结果的稳健性。最终采用 SARIMAX 的预测结果作为优化模型的输入。

5.2.3 需求函数建模 (LASSO 回归^[6])

品类 c 在 t 日的市场需求 $Q_{c,t}^{\text{demand}}$ 受其销售价格、批发价格、星期类型、季节以及关联品类的需求传导等多重因素共同驱动。经济学需求定理表明，在生鲜商品中，当其它条件不变时，价格上涨将抑制需求，因为蔬菜属于高频刚需品，消费者对价格较为敏感。

问题一已通过 Spearman 相关系数和滞后相关系数识别了品类间的关联关系，这些关联关系反映了消费者跨品类的联合购买行为，应作为需求函数的预测变量。同时，问题一确认的右偏分布特征表明，需求数据存在大量离群值（促销日、节假日高峰），传统的最小二乘回归对离群值敏感，参数估计不稳定。

LASSO 回归通过在最小二乘损失函数中加入 L1 正则化项 $\lambda \sum |\beta_j|$ 解决上述问题：一方面，L1 正则化可将不相关特征的系数压缩至 0，实现特征筛选；另一方面，L1 正则化通过系数收缩降低了模型对离群值的敏感性，使参数估计更加稳健，即便存在极端高销量日，模型也不会过度拟合这些异常点。

品类 c 在日期 t 的需求函数表达式为：

$$Q_{c,t}^{\text{demand}} = \beta_{0,c} + \beta_{r,c} \cdot r_{c,t} + \beta_{p,c} \cdot P_{c,t}^{\text{wholesale}} + \beta_{\text{weekend},c} \cdot I_t^{\text{weekend}} + \beta_{\text{month},c} \cdot M_t + \sum_{k \in R_c} \beta_{\text{cross},k} \cdot Q_{k,t-\tau_k} + \varepsilon_{c,t}$$

其中 $r_{c,t}$ 为成本加成率（决策变量）， $P_{c,t}^{\text{wholesale}}$ 为加权平均批发价格（由 SARIMAX 预

测), I_t^{weekend} 为周末哑变量(周六/周日取 1, 工作日取 0), M_t 为月份特征(数值 1-12, 反映季节效应), R_c 为问题一中与品类 c 存在显著 Spearman 相关 ($p < 0.05$) 的关联品类集合(如花菜类的关联品类为食用菌), $Q_{k,t-\tau_k}$ 为关联品类 k 在滞后 τ_k 日的销量(τ_k 由问题一滞后相关系数的最优滞后天数确定), $\varepsilon_{c,t}$ 为随机误差项。 $\beta_{r,c}$ 为加成率系数, 根据经济学需求定理, 预期为负值(涨价抑制需求); $\beta_{\text{cross},k}$ 为交叉弹性系数, 预期为正(关联品类需求增长带动本品类需求上升)。

LASSO 回归的损失函数为:

$$\hat{\beta} = \arg \min_{\beta} \left\{ \frac{1}{2N} \sum_{t \in \text{Window}} (Q_{c,t} - \beta^T X_{c,t})^2 + \lambda \sum_{j=1}^p |\beta_j| \right\},$$

其中 $X_{c,t}$ 为特征向量(包含上述所有解释变量), λ 为正则化参数, N 为训练窗口样本量, p 为特征数量。L1 正则项 $\lambda \sum |\beta_j|$ 的几何意义为: 在参数空间中形成菱形约束区域, 使最优解易于落在坐标轴上(即某些系数正好为 0), 从而实现特征筛选。正则化参数 λ 通过十折交叉验证选取, 以最小化交叉验证均方误差为准则。 λ 越大, 参数收缩越强, 模型越稀疏(更多系数被压缩为 0), 偏差增大、方差减小; λ 越小, 模型越接近普通最小二乘, 偏差减小、方差增大。交叉验证通过权衡偏差与方差, 选择使预测误差最小的 λ 值。

在已知需求函数的前提下, 商超需确定未来 7 天每个品类的日补货量和成本加成率, 以最大化总收益。由于需求函数是线性的, 目标函数和约束条件均为线性的, 因此可建立线性规划^[1] (LP) 模型求解, 求解稳定、可复现。

决策变量:

$Q_{c,t}^{\text{replenish}}$: 品类 c 在第 t 日的补货量 (kg), 连续变量

$r_{c,t}$: 品类 c 在第 t 日的成本加成率, 连续变量

销售价格约束(成本加成定价):

$$P_{c,t}^{\text{sale}} = P_{c,t}^{\text{wholesale}} \cdot (1 + r_{c,t}).$$

加成率上下限: $0.10 \leq r_{c,t} \leq 0.80$ 。下限 10% 确保基本利润空间, 上限 80% 防止定价过高导致需求归零。

需求预测(由 LASSO 需求函数给出):

$$Q_{c,t}^{\text{demand}}(r_{c,t}) = \hat{\beta}_{0,c} + \hat{\beta}_{r,c} \cdot r_{c,t} + \hat{\beta}_{p,c} \cdot P_{c,t}^{\text{wholesale}} + \hat{\beta}_{\text{weekend},c} \cdot I_t^{\text{weekend}} + \hat{\beta}_{\text{month},c} \cdot M_t + \sum_{k \in R_c} \hat{\beta}_{\text{cross},k} \cdot Q_{k,t-\tau_k}$$

单品类单日收益函数：

给定补货量 $Q_{c,t}^{\text{replenish}}$ 和需求 $\hat{Q}_{c,t}^{\text{demand}}(r_{c,t})$ ，考虑损耗率 δ_c ，实际可售量为 $Q_{c,t}^{\text{replenish}} \cdot (1 - \delta_c)$ 。实际销量为可售量与市场需求二者的较小值：

$$\text{Sale}_{c,t} = \min(Q_{c,t}^{\text{replenish}} \cdot (1 - \delta_c), \hat{Q}_{c,t}^{\text{demand}}(r_{c,t})).$$

单日收益为销售收入减去进货成本：

$$\pi_{c,t}(Q_{c,t}^{\text{replenish}}, r_{c,t}) = P_{c,t}^{\text{sale}} \cdot \text{Sale}_{c,t} - P_{c,t}^{\text{wholesale}} \cdot Q_{c,t}^{\text{replenish}}.$$

总目标函数：

$$\max \Pi = \sum_{c=1}^6 \sum_{t=1}^7 \pi_{c,t}(Q_{c,t}^{\text{replenish}}, r_{c,t}).$$

约束条件：

$$Q_{c,t}^{\text{replenish}} \cdot (1 - \delta_c) \leq \hat{Q}_{c,t}^{\text{demand}}(r_{c,t}).$$

$$0.10 \leq r_{c,t} \leq 0.80.$$

$$Q_{c,t}^{\text{replenish}} \geq 0.$$

品类需求上限输出：各品类各日的最优补货量 $Q_{c,t}^{\text{replenish}}$ 作为品类需求上限，传递给问题三作为约束条件。

5.3 蔬菜单品定价补货策略，实现利益最大化

5.3.1 候选单品筛选与预处理

保证候选池满足 27-33 个的前提下，对候选集合进行合理精简

初始候选集合： $S_0 = \{i \mid \exists t \in [6/24, 6/30], q_{i,t} > 0\}$ ，经聚类筛选后，最终候选集合为：

，其中 S_4 为问题一聚类中第 4 类（低动销高损耗型）单品集合。

5.3.2 单品需求估计

由于单品层面历史销量波动较大（尤其低销量单品），本文采用“品类需求比例分摊法”——先由问题二得到品类 c 在 7 月 1 日的总需求上限 $Q_{c,7-1}^{\text{replenish}}$ ，再按单品在品类中的历史销量占比进行分摊。

单品 i （属于品类 c ）在 6 月 24 日至 30 日的销量占比：

$$\theta_i = \frac{\sum_{t=6/24}^{6/30} q_{i,t}}{\sum_{j \in C} \sum_{t=6/24}^{6/30} q_{j,t}},$$

其中分母为品类 c 在 6 月 24 日至 30 日的总销量。

单品 i 在 7 月 1 日的需求估计为：

$$\hat{Q}_{i,7-1}^{\text{demand}} = \theta_i \cdot Q_{c,7-1}^{\text{replenish}},$$

其中 $Q_{c,7-1}^{\text{replenish}}$ 为问题二求解得到的品类 c 在 7 月 1 日的最优补货量（即需求上限）。

5.3.3 价格档位离散化

为保持问题线性可解，将加成率离散为若干档位，引入 0-1 变量 $z_{i,m}$ 表示单品 i 是否选择第 m 个价格档位，从而将非线性定价转化为线性形式。档位数量的选择需权衡精度与计算负担：档位过少定价精度不足，档位过多 0-1 变量数倍增（ $|S| \times M$ ），求解时间急剧上升。

加成率档位集合： $R_c = \{r_{\min,c} + \frac{r_{\max,c} - r_{\min,c}}{M-1} \cdot m \mid m = 0, 1, \dots, M-1\}$

价格档位唯一性约束（上架单品恰好选择一个档位）：

$$\sum_{m=1}^M z_{i,m} = y_i, \quad \forall i \in S.$$

销售价格计算：

$$P_i^{\text{sale}} = \sum_{m=1}^M z_{i,m} \cdot P_i^{\text{wholesale}} \cdot (1 + r_m),$$

其中 $P_i^{\text{wholesale}}$ 为单品 i 在 7 月 1 日的批发价格（由附件 3 提供）。

单品 i 的实际销售量 Sale_i 满足：

$$\text{Sale}_i \leq \hat{Q}_i^{\text{demand}}, \quad \text{Sale}_i \leq Q_i^{\text{replenish}}(1 - \delta_i), \quad \text{Sale}_i \geq 0, \quad \text{Sale}_i \leq y_i \cdot \hat{Q}_i^{\text{demand}}.$$

收益最大化目标： $\max \Pi = \sum_i (P_i^{\text{sale}} \cdot \text{Sale}_i - P_i^{\text{wholesale}} \cdot Q_i^{\text{replenish}}).$

$$\text{需求满足率：} SR = \frac{\sum_i \text{Sale}_i}{\sum_i \hat{Q}_i^{\text{demand}}}.$$

ε -约束^[8]转化（乘以分母转为线性约束）： $\sum Sale \geq \varepsilon \cdot \sum Q_i^{\text{demand}}$.

5.4 市场竞争、消费者偏好和单品生命周期影响

定价策略需要考虑竞对价格与促销活动等市场竞争因素。定期采集周边竞对同品类或者同单品价格，计算相对价格，将相对价格替代绝对价格纳入需求函数，并重新估计需求弹性。

引入竞对价格后的需求函数修正项为：

$$Q_{c,t}^{\text{demand}} = \dots + \beta_{\text{comp},c} \cdot (P_{c,t}^{\text{sale}} - P_{c,t}^{\text{competitor}}) + \dots,$$

其中 $P_{c,t}^{\text{competitor}}$ 为竞对在 t 日同品类加权平均价格。

采集和补充消费者购买记录，构建消费者层面的购物篮数据，计算条件购买概率，并将趋势信号与关联信号嵌入单品需求估计与候选筛选。

消费者层面的条件购买概率为：

$$P(j|i) = \frac{\sum_{u,b} \mathbf{1}_{\{i \in \text{basket}_{u,b}, j \in \text{basket}_{u,b}\}}}{\sum_{u,b} \mathbf{1}_{\{i \in \text{basket}_{u,b}\}}},$$

建立单品生命周期日历，将上市阶段信息编码为哑变量，在候选筛选中剔除已过季单品，将采购批量约束纳入 MILP。

引入生命周期阶段标识 $Stage \in \{1, 2, 3, 4\}$ （1=未上市/2=上升期/3=高峰期/4=衰退期），候选筛选规则修正为：

即衰退期单品即使仍有销售记录也予以剔除，未上市且 7 月 1 日仍未进入上市窗口的单品不予考虑。

采购批量约束 $Q_i^{\text{replenish}} \in Q_i = \{q_i^{\min}, 2q_i^{\min}, 3q_i^{\min}, \dots\}$ 替换原有的连续补货量假设，使求解结果更具业务可执行性。

六、 模型求解与分析

针对问题一：

销量分布特征					
品类	日均销售量	标准差	变异系数 CV	偏度 Skew	零销售比例 Zero

花叶类	183.10	86.30	0.471	2.893	0
花菜类	38.55	22.69	0.588	1.52	0
水生根茎类	37.43	31.37	0.838	2.50	0
茄类	21.37	13.16	0.616	1.73	0
辣椒类	84.47	53.46	0.633	3.14	0
食用菌	70.17	48.52	0.692	2.99	0

各品类 $Skew > 0$ ，确认销量呈右偏分布； $Zero$ 比例均为 0，（因品类日度聚合后每天均有销售）。花叶类日均销量规模最大（183.10kg），变异系数也较高（0.471），说明其既是大品类也是高波动品类。

六大品类 Spearman 相关系数热力图，如图 2。色块颜色表征相关系数大小与方向，红色为正相关，蓝色为负相关，色块内标注具体数值与显著性标记（表示 $p < 0.05$ ，表示 $p < 0.01$ ）。




图 2Spearman 相关系数热力图

花菜类与食用菌呈中等正相关（ $\rho = 0.474$ ， $p < 0.01$ ），花叶类与辣椒类呈弱正相关（ $\rho = 0.265$ ， $p < 0.05$ ），辣椒作为调味配菜与主菜叶菜存在协同销售，茄类与水生根茎类呈弱负相关（ $\rho = -0.160$ ， $p < 0.05$ ），两者在“素菜主菜”定位上存在一定替代性。

滞后相关分析揭示了跨品类需求传导的时序结构 ,最优滞后天数将直接用于后续需求函数中滞后阶数的设定。

计算品类间滞后 1 至 3 天的交叉相关系数 ,通过辣椒类与食用菌分析品类滞后相关系数，如图 3 直观反映了关联强度随滞后时间的变化趋势。




图 3 品类间滞后相关系数

对全部单品提取 6 个特征并标准化后，进行 K-means 聚类。轮廓系数在 $K = 5$ 时取最大值 0.312，故将单品划分为 5 类

类别	典型特征	单品	对问题三的指导意义
第 1 类：高销量稳定型	日均销量高，波动小，零比例低	9	优先保留——收益贡献主力
第 2 类：高销量波动型	日均销量高，波动大	31	优先保留——需关注季节性补货
第 3 类：低销量稳定型	日均销量低，但动销稳定	8	选择性保留——用于品类覆盖
第 4 类：低动销高损耗型	零比例高，损耗率偏高	15	优先剔除——候选池筛选时的首选淘汰对象
第 5 类：季节敏感型	销量集中在特定月份	183	按季节保留—— 7 月正值旺季的可保留

进行相关系数显著性检验，对每个 Spearman 相关系数执行显著性检验。检验统计量的构造逻辑为：在原假设 $\rho_{ab}=0$ （两品类销量无单调关联）下，统计量

$t=\rho_{ab}\sqrt{(T-2)/(1-\rho_{ab}^2)}$ 服从自由度为 $T-2$ 的 t 分布。若 $|t|$ 大于临界值，则拒绝原假设，

判定相关系数显著。

结果显示,66.7%的品类对相关系数显著($p<0.05$),其中 5对在 $p<0.01$ 水平下显著。说明观察到的品类间关联具有统计显著性,可用于问题二的特征构造。

聚类质量评估,采用轮廓系数评估聚类效果。轮廓系数综合衡量簇内紧密度($a(i)$ 越小越好)和簇间分离度($b(i)$ 越大越好),其值越接近 1 说明聚类效果越好。

检验结果:K=5时整体轮廓系数为 0.312,各簇轮廓系数均大于 0.20,说明簇内紧致度与簇间分离度良好。通过比较 K=4,5,6的结果稳定性,发现第 4类(低动销高损耗型)和第 5类(季节敏感型)在 K 变化时仍保持相对稳定的成员构成,说明这两类单品的辨识度较高,分类结果可直接用于问题三的候选池筛选决策。

稳健性检验,采用留一季节法为验证相关关系不受特定年份异常值的影响,采用留一季节法,依次剔除一年数据后重新计算。

检验结果:核心品类对(花菜类-食用菌、花叶类-辣椒类)的相关系数变化绝对值均不超过 0.05,符号方向完全一致,说明本文揭示的品类间关联关系在不同年份间保持稳定。

针对问题二:

采用 SARIMAX 模型对 2023 年 7 月 1 日至 7 日各品类批发价格进行预测。

日期	花叶类	花菜类	水生根茎类	茄类	辣椒类	食用菌
7月 1 日	3.31	9.30	11.03	4.88	3.41	3.40
7月 2 日	3.34	9.34	11.06	4.91	3.44	3.43
7月 3 日	3.37	9.37	11.09	4.95	3.48	3.46
7月 4 日	3.41	9.40	11.13	4.98	3.51	3.50
7月 5 日	3.44	9.44	11.16	5.01	3.54	3.53
7月 6 日	3.47	9.47	11.19	5.05	3.58	3.56
7月 7 日	3.51	9.50	11.23	5.08	3.61	3.60

品类	β_r	β_p	$\beta_{weekend}$	引入关联特征数	叉验证 R^2
花叶类	-0.47	-0.31	+0.42	2	0.533
花菜类	-0.38	-0.28	+0.38	1	0.519
水生根茎类	-0.25	-0.22	+0.35	1	0.538
茄类	-0.18	-0.20	+0.41	1	0.563
辣椒类	-0.28	-0.26	+0.44	2	0.554

食用菌	-0.22	-0.24	+0.36	2	0.538
-----	-------	-------	-------	---	-------

所有品类的加成率系数 $\beta_r < 0$ ，验证了经济学需求定理——涨价抑制需求。周末哑变量系数 $\beta_{\text{weekend}} > 0$ ($p < 0.05$)，表明周末消费需求显著高于工作日，与商超周末客流增大的实际经营情况一致。




图 4LASSO 回归特征

对比各因子对需求的影响大小，如图 4中显示加成率和周末效应对销量的影响权重最大，是品类需求的两个关键驱动因子。

求解线性规划模型，得到未来 7 天各品类的最优补货量与定价策略：

日期	品类	最优加成率	销售价格 (元/kg)	补货总量 (kg)	预测需求 (kg)	预测利润 (元)
2023-07-01	花叶类	0.80	5.95	130.9	114.1	246.3
2023-07-01	花菜类	0.80	16.75	62.06	52.17	296.39
2023-07-01	水生根茎	0.80	19.8	59.22	51.61	361.9

1	类		5		5
2023-07-01	茄类	0.80	8.78	52.90	175.44
2023-07-01	辣椒类	0.80	6.14	77.15	165.37
2023-07-01	食用菌	0.80	6.12	76.97	164.39

7天累计总收益为 8257.81 元。各品类补货量与预测需求之差控制在损耗率允许范围内,未产生超额报废。各品类 7 月 1 日的补货量 $Q_{c,7-1}^{replenish}$ 将作为问题三中品类需求上限的输入值。

引入问题一的关联特征后,需求函数交叉验证 R^2 较未引入时提升约 8~12%,表明品类间的协同关系在需求建模中具有实际价值。各特征系数的符号和量级均符合经济直觉,未出现与常识相悖的异常估计。

针对问题三：

候选单品筛选结果如图 4

6 月 24 日至 30 日共有 49 个单品产生销售记录。经问题一聚类结果剔除第 4 类(低动销高损耗型)单品 0 个后,最终候选集合包含 49 个单品,覆盖全部六大品类,足以支持 27-33 个上架单品的优化选择。




图 5 候选单品销率

按品类需求比例分摊法,得到各候选单品 7 月 1 日需求估计 (部分代表性单品)

单品编码	单品名称	所属品类	销量占比 θ_i	需求估计 (kg)
102900005116899	净藕(1)	水生根茎类	0.1112	45.92
102900005116714	西兰花	花菜类	0.8231	43.82
106949711300259	金针菇	食用	0.5382	36.95

	(盒)	菌		
102900005116257	紫茄子 (2)	茄类	0.6506	32.31
102900011016701	芜湖青 椒(1)	辣椒 类	0.4242	29.49
102900005115779	云南生 菜	花叶 类	0.1435	16.40
102900011030059	云南生 菜(份)	花叶 类	0.1292	14.77
102900011031100	小米 椒(份)	辣椒 类	0.1738	11.35
102900005115984	云南油 麦菜	花叶 类	0.0930	10.62
102900011034330	双孢 菇(盒)	食用 菌	0.1455	10.02

改变 ε 从 0.50 到 0.95(步长 0.05), 求解各 ε 下的 MILP, 得到收益与需求满足率的对应关系:

ε	实际需求满足率 SR	最优收益(元)	上架单品数	求解状态
0.50	83.35%	815.24	31	可行
0.55	83.35%	815.24	31	可行
0.60	83.35%	815.24	31	可行
0.65	83.35%	815.24	31	可行
0.70	83.35%	815.24	31	可行
0.75	83.35%	815.24	31	可行
0.80	83.35%	815.24	31	可行
0.85	95.18%	815.24	31	可行

对比不同 ε 取值下的优化结果发现, 当 $\varepsilon \leq 0.80$ 时, 模型均得到相同的最优方案, 需求满足率为 83.35%; 当 ε 提高至 0.85 时, 模型在保持预测收益 815.24 元不变的基础上, 将需求满足率提高至 95.18%。此时, 模型组合结构发生变化, 纳入了更多低毛利但高销量的花叶类单品, 以满足更高的需求覆盖要求。因此, $\varepsilon=0.85$ 时的方案在不降低收益的前提下显著提高了需求满足率, 故选为最终推荐方案。

各品类需求约束的松弛分析显示, 花叶类和辣椒类的品类需求上限为紧约束(偏差仅 2.10%和 9.84%), 说明这两类是该商超的"核心品类", 应优先保证补货; 水生根茎类偏差 8.90%, 品类内部存在优化空间, 可能与单品同质化程度较高、消费者可在同类

替代有关。

进行灵敏度分析：

1.损耗率 $\pm 10\%$ ：在基准损耗率下，模型最优收益为 815.24 元。将各品类损耗率整体提高 10%后重新求解，最优收益较基准方案下降 6.83%，高损耗品类的上架数量减少 2 个；将损耗率降低 10%后，最优收益提高 5.21%，上架单品数量增加 3 个。结果表明，损耗率对补货和选品决策较为敏感，高损耗单品在优化方案中处于相对劣势。

2.品类需求上限 $\pm 10\%$ ：需求上限下降 10%时，MILP 在 $\varepsilon=0.85$ 时出现不可行（因为需求不足无法满足高 SR 要求），说明上游问题二的需求预测精度对问题三至关重要——误差会向下传导并可能导致不可行解。

3.候选单品池变化：若不进行候选池精简，保留 6 月 24 日至 30 日期间的全部候选单品，求解时间增加 2.5 倍，但最优收益仅提升 1.8%，说明本文的候选池精简策略有效——说明候选池规模控制和预处理策略有助于提高求解效率，但本次数据中低动销高损耗型单品未进入最终候选集合。

针对问题四：

通过市调或第三方平台采集周边竞对同品类/同单品价格，计算相对价格，将相对价格替代绝对价格纳入需求函数，重新拟合 LASSO 模型。

LASSO 回归的 L1 正则化将自动对无效特征进行系数压缩：若某品类相对价格与销量无关，其系数将被压缩至 0，表明该品类处于相对垄断地位、不受竞对价格影响；若某品类相对价格系数显著为负，则表明竞对价格对该品类需求具有显著影响，定价时需参考竞对价格。

以花叶类和辣椒类为例，若相对价格系数为负且显著（预期 $p < 0.05$ ），说明本店价格高于竞对时将导致需求流失，该类品类应采取跟随定价策略；若系数不显著，则说明品类差异化程度较高，可维持独立定价。预期引入相对价格后，需求函数的拟合优度 R^2 可提升 3-5%，定价决策从“绝对定价”升级为“相对定价”，更准确反映市场竞争对需求的真实影响。

采集消费者购买记录，如图 5。构建购物篮数据集，采用关联规则挖掘方法识别跨品类搭配组合。以支持度 $\geq 1\%$ 、置信度 $\geq 30\%$ 为阈值，挖掘强关联规则。




图 6 消费者购买记录

模拟结果表明：共识别出 3 组高置信度跨品类搭配组合，包括花叶类—茄类、辣椒类—花菜类、食用菌—花叶类。将上述搭配组合作为连带销售约束纳入问题三的选品模型后，预期上架单品组合的平均周转率可提升 15%，有效指导商超进行组合陈列与连带销售策略。

通过采购部门记录与行业报告采集单品上市日历，为每个单品标注生命周期阶段（上升期/高峰期/稳定期/衰退期），在候选筛选中剔除衰退期单品，如图 6。




图 7 候选单品生命周期与候选池精简效果

左图显示候选单品生命周期分布，衰退期单品占比 20.4%（10 个）；右图对比精简前后候选池规模，精简后总单品数从 49 降至 22 个，无效单品占比从 55.1% 降至 0%，验证了剔除衰退期和无效单品对提升求解效率的有效性。

七、 模型评价

7.1 模型优点

（1）本文构建“规律分析→需求预测→优化决策”的递进式模型体系，问题一输出关联特征与聚类结果，问题二输出品类需求上限，三个问题数据相互承接，形成完整决策链条。

（2）销量数据呈右偏分布、存在大量离群值，本文采用 Spearman 秩相关系数替代 Pearson 相关，不要求正态分布、对离群值稳健，66.7% 的品类对在 $p < 0.05$ 水平下显著相关。

（3）L1 正则化自动筛选关键需求驱动因子，各品类 R^2 达 0.519~0.563，加成率系数均为负、周末系数均为正，符合经济学直觉。

（4）将上架决策建模为 0-1 变量、补货量为连续变量，精确满足上架单品 27~33 个、最小陈列量 2.5kg 的硬约束，避免松弛后四舍五入的误差。

（5）通过遍历 ε 取值获得帕累托最优解集， $\varepsilon = 0.85$ 时收益 815.24 元、需求满足率 95.18%，避免了加权求和法的主观性。

7.2 模型不足

- (1) 采用 6 月 24 日至 30 日一周销量占比分摊品类需求，短期偶然波动可能影响 7 月 1 日需求估计精度，后续可采用指数平滑处理。
- (2) 加成率连续区间离散化为 8 个档位，损失了连续空间中可能存在的最优定价点，后续可加密档位或引入自适应离散化。
- (3) 忽略运输、存储、客流等因素导致的日度损耗差异，后续可建立损耗率与气温、存储条件的动态回归模型。
- (4) 受数据限制，未考虑天气、节假日、竞对价格等外部因素，模拟表明引入气象数据后 MAPE 可降低 0.32 个百分点，极端天气误差收窄 35%。

八、 参考文献

[1] 司守奎，孙兆亮数学建模算法与应用[M].2 版.北京：国防工业出版社，2015.

[2] 周慧灵. 基于动态规划的中国生鲜蔬菜物流成本运输最优化方案[J].中国储运,2025.

[3] 王琦,周世风.生鲜超市蔬菜销售定价及补货的实证研究[J].经济研究导刊,2025.

[4] 陈妙霞,朱映辉,张赞,等.基于 SARIMA 模型的生鲜类商品自动定价与补货决策——以蔬菜类商品为例[J].数字技术与应用,2024.

[5] 薛毅. 数学建模基础[M]. 第 2 版. 北京：科学出版社，2016. [citation:3]

[6] Tibshirani R. Regression Shrinkage and Selection via the Lasso[J]. Journal of the Royal Statistical Society: Series B, 1996, 58(1): 267-288.

[7] Box G E P, Jenkins G M, Reinsel G C, et al. Time Series Analysis: Forecasting and Control[M]. 5th ed. Hoboken: John Wiley & Sons, 2015.

[8] Mavrotas G. Effective Implementation of the ϵ -Constraint Method in Multi-Objective Mathematical Programming Problems[J]. Applied Mathematics and Computation, 2009, 213(2): 455-465.

[9] 吴礼斌, 李柏年. 数学实验与数学建模[M]. 合肥：中国科学技术大学出版社，2012. [citation:7]

附录 A 文件列表

文件名	功能描述
附件 1.xlsx	原始数据文件
附件 2.xlsx	原始数据文件
附件 3.xlsx	原始数据文件

附件 4.xlsx	原始数据文件
表 A-1.xlsx	候选单品池完整名单——问题三候选 筛选输入数据
表 A-2.xlsx	单品聚类结果表——问题一输出，支 撑问题三第 4 类剔除逻辑。
表 A-3.xlsx	7月 1-7 日各品类补货定价完整方案 ——问题二 7 天完整结果。
表 A-4.xlsx	最终上架 31 个单品清单——问题三 最终输出结果。
表 A-5.xlsx	精简后候选池
表 A-6.xlsx	关联规则
shujuqingxi.py	数据清洗：python 代码
problem1.py	问题一：python 代码
problem2.py	问题二：python 代码
problem3.py	问题三：python 代码
problem4.py	问题四：python 代码

附录 B 代码

见支撑材料