

面向生鲜商超的蔬菜销量分析与补货定价优化研究

摘要

生鲜商超蔬菜类商品保鲜期短、当日未售即损耗，补货与定价决策直接影响经营收益。本文围绕蔬菜品类与单品的销量规律、品类级补货定价优化、新品引入决策以及经营数据采集四个问题，构建了"统计分析—需求预测—优化决策"的完整建模体系。

针对问题一，首先对销售流水进行退货剔除、四分位法异常值识别与按日聚合等预处理；进而从分布规律与相互关系两个维度展开分析。结果表明：六大品类日销量均呈右偏分布，其中食用菌、辣椒类服从**对数正态分布**；品类内部单品销量呈典型"二八"长尾特征；销量存在显著季节周期与"10—12时、16—18时"的日内双峰规律，周末销量显著高于工作日。基于**斯皮尔曼秩相关**与**Apriori**购物篮分析发现，品类间以互补关系为主，并识别出茼蒿—竹叶菜、红椒—青线椒等高提升度互补单品组合。

针对问题二，构建**SARIMAX**多变量**时间序列**需求预测模型，将定价、批发价、星期、月份、打折标识作为外生协变量，建立定价与潜在需求的动态映射；在此基础上以七天总利润最大为目标，考虑损耗率、最小陈列量与价格区间约束，采用实数编码遗传算法求解84维补货—定价联合优化问题。模型约80代收敛，得到2023年7月1日至7日各品类最优日补货量与定价方案，预期七天**总利润8780元**，较经验基准方案明显提升；敏感性分析表明模型对损耗率与最小陈列量的响应符合经济直觉。

针对问题三，面对4个待引入新品无本地销售记录的冷启动难题，采用特征迁移思路：以同品类历史单品样本训练**BP神经网络**，学习商品属性、价格、时间特征与需求量的非线性映射，实现新品需求预估；进而构建含0-1引入变量与连续补货、定价变量的**混合整数非线性规划**模型，用混合编码**遗传算法**求解，并通过不引入新品的对照组，从收益、品类销量、损耗三个维度定量评估新品引入的综合影响。

针对问题四，按照需求侧、供给与供应链侧、门店运营库存侧、外部环境四个类别，梳理了订单数据、缺货记录、分时客流、产地供货、陈列空间、库存盘点、节假日与气象等待采集数据，阐明各类数据对修正关联分析、降低预测误差、细化优化约束与改善新品冷启动的作用，并给出采集落地路径与模型改进方向。

关键词：蔬菜补货与定价；SARIMAX需求预测；遗传算法；BP神经网络

一、问题重述

生鲜商超所售卖的蔬菜普遍保鲜周期短，商品品质会随着售卖时长持续衰减，多数蔬菜若当日无法完成销售，次日便不再具备售卖条件，这就要求商超结合历史销售情况与市场需求，每日完成补货工作。蔬菜品类繁杂，货源产地各不相同，采购交易大多集中在凌晨 3 点至 4 点开展，商家在无法完全掌握单品实际行情与进货价格的条件下，就要完成当日各类蔬菜的补货决策。商超对蔬菜大多采用成本加成的定价模式，对于出现损耗、品相下滑的商品，一般会采取打折的方式进行促销。因此开展市场需求分析，对补货与定价工作具备很强的现实意义。从需求角度来看，蔬菜的销量往往和时间因素存在联系；从供给角度来看，每年 4-10 月蔬菜供给充足，同时门店销售空间有限，如何搭建合理的商品销售组合，也是经营过程中需要解决的关键问题。

本文给定某商超 2020-07-01 至 2023-06-30 期间的商品基础档案、销售流水记录、批发价格以及损耗统计共四组附件数据，需要构建数学模型完成以下四项任务：

问题一：探究不同蔬菜品类、单品的销量分布特征，挖掘各品类之间存在的内在关联。

问题二：以品类作为决策单元制定补货方案，探究蔬菜品类总销量与成本加成定价之间的内在联系，求解未来一周（2023-07-01 至 2023-07-07）各个品类每日补货规模以及定价方案，实现商超经营收益最大化。

问题三：基于第二问的模型框架引入新增蔬菜单品，在在售单品数量、单品最低订货量 2.5 千克、货架存储能力等现实约束下，完成新品筛选工作，确定入选新品的补货量与销售价格，同步优化原有蔬菜品类的经营方案，最大化商超整体收益。

问题四：为提升蔬菜补货、定价决策的实际效果，分析商超还需要补充采集哪些维度的数据，并阐述各类数据对于求解上述问题的价值与依据。

二、问题分析

问题一的分析：问题一要求挖掘蔬菜品类与单品销售量的分布规律及相互关系，属于典型的统计分析与数据挖掘问题。原始销售流水粒度细、体量大，且包含退货与异常记录，需先完成数据清洗、按日聚合与品类映射等预处理。分布规律方面，采用描述性统计与 KS 分布拟合优度检验刻画销量的概率分布形态，结合帕累托分析、月度箱线图与日内时段统计，从单品集中度、季节与日内三个层面揭示销量规律；相互关系方面，考虑到销量序列不服从正态分布，选用斯皮尔曼秩相关衡量品类间单调关联，并构建虚拟购物篮、采用 Apriori 算法挖掘单品间的互补与替代关系，最后单独分析打折促销对销量分布的扰动。

问题二的分析：问题二要求以品类为单位给出未来一周的日补货总量与定价策略，本质是带需求不确定性的库存—定价联合优化问题。定价提高可提升单位毛利但抑制需求，补货过量产生损耗、不足造成缺货，二者强耦合。本文将其拆解为两个联动子模型：一是需求预测子模型，采用 SARIMAX 模型，将定价作为外生协变量，建立“定价—潜在需求”的动态映射；二是优化决策子模型，以七天总利润最大为目标，叠加损耗、最小陈列量与价格区间约束。由于需求函数非线性且含 min 算子，目标函数非光滑，宜采

用遗传算法全局寻优，并通过敏感性分析检验模型稳健性。

问题三的分析：问题三在问题二基础上引入 4 个无本地销售记录的新单品，同时存在货架资源竞争与新旧商品间的互补替代效应，不能独立求解。其核心难点是新品需求的冷启动预测：可利用新品所属品类、批发价、损耗率等属性信息，采用特征迁移思路，用同品类历史单品样本训练 BP 神经网络预估新品需求；进而构建同时包含 0-1 引入变量与连续补货、定价变量的混合整数非线性规划模型，采用混合编码遗传算法求解，并设置不引入新品的对照组定量评估新品影响。

问题四的分析：问题四为开放性论述题，应从建模过程中暴露的数据短板出发回答。前三问的求解依赖若干近似假设（如虚拟购物篮、重量上限货架约束、固定损耗率），均源于数据维度不足。按照业务逻辑将待采集数据划分为需求侧、供给与供应链侧、门店运营库存侧、外部环境四类，逐项说明其对修正关联分析、改进需求预测、细化优化约束与缓解新品冷启动的作用，并给出采集落地路径。

文章整体思路如图 1 所示：




图 1 总体思路图

三、模型假设

结合赛题背景与商超实际经营场景，为保证模型可运行且结果具备现实意义，做出如下总体假设：

假设一：预测期内不发生重大突发事件，居民消费习惯与蔬菜产地供给水平与历史样本期保持一致，市场需求结构不出现结构性突变。

假设二：同一品类内部不同单品的批发价格存在差异，以各单品历史销量为权重计算品类层面的加权平均批发价格，作为该品类每日的进货成本。

假设三：各品类损耗率采用附件 4 给出的近期平均损耗率，损耗发生在当日营业结束之后，未售出部分全部计入损耗成本，不跨天留存销售。

假设四：不考虑跨品类缺货替代效应，即某一品类缺货时，消费者不会大规模转向购买其他品类蔬菜。

假设五：每日补货在营业开始前一次性完成，营业期间不进行二次补货。

假设六：预测模型输出的需求量代表该定价水平下的市场潜在需求，当补货扣除损耗后的可售量大于潜在需求时，实际销量等于潜在需求；当可售量小于潜在需求时发生缺货，实际销量等于可售量。

假设七：数据集中未提供订单编号，将短时间窗口内连续发生的多条收银流水近似视作同一位消费者的一次购物，用于构建购物篮事务数据。

四、符号说明

为便于后续模型表述，将全文涉及的主要符号及含义整理如下表。其中下标 $i=1,2,\dots,6$ 依次代表花叶类、辣椒类、水生根茎类、食用菌、茄类、花菜类六个蔬菜品类， $t=1,2,\dots,7$ 代表 2023 年 7 月 1 日至 7 日的预测周期；各问题专用符号在对应章节中另行说明。

表 1 详细技术参数表

符号	含义	来源/说明
Q_1 、 Q_3 、 IQR $Skew$	第一、第三四分位数与四分位距 样本偏度	数据预处理（式 1） 分布规律分析（式 3） 分布拟合优度检验（式 4）
D_n	KS 检验统计量	品类相关性分析（式 5）
ρ_s	斯皮尔曼秩相关系数	购物篮分析（式 6）
$Support$ 、 $Confidence$ 、 $Lift$	关联规则的支持度、置信度、提升度	SARIMAX 模型（式 7）
y_t 、 $x_{k,t}$ 、 β_k	第 t 期销量、第 k 个外生协变量及其回归系数	待优化求解
$Q_{i,t}$	第 i 个品类第 t 天的补货量（决策变量）	待优化求解
$P_{i,t}$	第 i 个品类第 t 天的销售定价（决策变量）	附件 3 计算
$C_{i,t}$	第 i 个品类第 t 天的加权平均批发进价	附件 4
r_i	第 i 个品类的平均损耗率	模型计算
$S_{i,t}$	第 i 个品类第 t 天扣除损耗后的实际可售量	时序预测模型输出
$D_{i,t}(P_{i,t})$	定价 $P_{i,t}$ 下的市场潜在需求量	模型计算
$Sale_{i,t}$	第 i 个品类第 t 天的实际销售量	附件 2 统计
$Q_{min,i}$	第 i 个品类每日最小陈列补货量	附件 2 统计
$P_{min,i}$ 、 $P_{max,i}$	第 i 个品类历史销售价格的上下限	模型计算
$\Pi_{i,t}$ 、 Π_{total}	单日单品类利润、七天总利润（优化目标）	问题三决策变量
x_k	第 k 个待引入新品是否引入的 0-1 变量	问题三约束参数
Cap	货架总容量上限	

五、问题一的模型建立与求解

5.1 数据预处理

5.1.1 数据清洗与样本筛选

为探究商超不同蔬菜品类、单品销售量的分布特征与相互关联关系，本文基于附件 2 的销售流水明细开展前期的数据预处理工作。原始流水记录了每一笔收银交易信息，其中包含部分退货交易，该类记录销量为负值，不能代表消费者真实购买行为，因此将

全部退货样本直接剔除^[1]。生鲜零售的实际业务场景中，系统录入失误会产生少量极端异常销量，若直接代入统计分析，会严重扭曲销量分布形态，本文采用四分位法完成异常样本识别，判别公式见式(1)。

$$\begin{cases} IQR = Q_3 - Q_1 \\ \text{下限} = Q_1 - 1.5 \times IQR \\ \text{上限} = Q_3 + 1.5 \times IQR \end{cases} \quad (1)$$

式中， Q_1 代表第一四分位数， Q_3 代表第三四分位数， IQR 为四分位距。对于销量超出上下限的极端样本做截断处理，最大程度保留真实交易信息，降低噪声数据对后续统计分析的干扰。

5.1.2 数据聚合与多表匹配

原始数据为逐笔交易的细粒度流水，单条记录仅对应一次顾客扫码行为，无法直接用于品类、单品层面的统计分析，需要对原始交易记录进行聚合运算。以单品编码作为关联关键字，将附件 1 中单品与所属品类的映射关系匹配至清洗完成的数据集。按照式(2)对销量进行按日聚合，分别得到品类日销量数据表与单品日销量数据表。

$$(S_{i,t} = \sum s_{i,t,k}) \quad (2)$$

$(S_{i,t})$ 表示第 i 个对象（品类或单品）在 t 日期下的日销售总量， $(s_{i,t,k})$ 为该对象在 t 日第 k 笔交易所对应的销量。品类日销量数据表统计六大蔬菜品类每日销售总重量，单品日销量数据表统计每一个单品每日销售重量，两张数据表作为后续分布规律与相关性分析的基础数据源。

5.1.3 衍生时间特征构建

依托原始数据的销售日期与扫码时刻，进一步构造衍生时间特征，将日期拆解为月份、星期字段，依据星期信息划分工作日与周末，同时保留每一笔交易的具体销售时刻。时序类数据挖掘中，时间特征的构建有助于挖掘季节、周度、日内的消费节律，完成上述处理之后，数据集已经满足分布规律与变量关联关系的实证分析条件。

5.2 蔬菜品类与单品销售量的分布规律分析

5.2.1 销量统计分布与拟合检验

对处理完成的六大品类日销量序列，计算均值、中位数、标准差、偏度、峰度等描述统计指标，统计结果汇总至表 1。

表 1 各品类日销量描述性统计表

品类	均值	标准差	最小值	中位数	最大值	偏度	峰度
花叶类	182.32	85.76	31.3	172.9	1264.91	2.9364	26.7541
食用菌	70.12	48.48	3.01	57.54	510.49	2.9967	16.8891
辣椒类	84.41	53.43	6.07	72.85	604.23	3.1466	18.4259

水生根茎类	36.53	30.1	0.93	30.29	296.25	2.6668	14.3163
茄类	21.25	13.03	0.25	18.76	117.46	1.7296	5.8348
花菜类	38.4	22.54	0.63	33.96	185.77	1.5034	4.0935

样本偏度的计算公式见式(3)，当偏度大于 0 时代表数据呈右偏分布^[4]。

$$Skew = \frac{n}{(n-1)(n-2)} \sum_{j=1}^n \left(\frac{x_j - \bar{x}}{\sigma} \right)^3 \quad (3)$$

式中，Skew 为样本偏度，n 代表样本容量， x_j 为样本观测值， $\bar{x}$ 为样本均值， σ 为样本标准差。从统计结果可以看出，六大蔬菜品类的日销量偏度均大于 0，属于典型的右偏分布，各品类中位数普遍低于均值，说明商超大部分营业日蔬菜销量维持在中等水平，少数特殊日期会出现销量冲高的现象。

为进一步判断销量数据符合哪一类理论概率分布，本文选取伽马分布、对数正态分布作为备选模型，采用 Kolmogorov-Smirnov 检验开展分布拟合优度检验，KS 检验统计量定义如式(4)。

$$D_n = \sup_x |F_n(x) - F_0(x)| \quad (4)$$

(D_n) 为 KS 检验统计量， $F_n(x)$ 是样本经验分布函数， $F_0(x)$ 为待检验的理论分布函数， $\sup$ 表示取上确界。将检验得到的统计量与 p 值整理进表 2，对比不同分布的拟合效果，以此定量描述蔬菜日销量的概率分布特点。

表 2 品类日销量分布 KS 检验结果表

品类	正态分布 p 值	正态分布结论	对数正态分布 p 值	对数正态分布结论	指数分布 p 值	指数分布结论
花叶类	0	拒绝正态	0.0259	拒绝对数正态	0	拒绝指数
食用菌	0	拒绝正态	0.5084	不拒绝对数正态	0	拒绝指数
辣椒类	0	拒绝正态	0.5266	不拒绝对数正态	0	拒绝指数
水生根茎类	0	拒绝正态	0	拒绝对数正态	0	拒绝指数
茄类	0	拒绝正态	0.0134	拒绝对数正态	0	拒绝指数
花菜类	0	拒绝正态	0.0007	拒绝对数正态	0	拒绝指数

聚焦到单品层面，数据表现出明显的长尾幂律特征，同一品类内部，只有少数头部爆款单品贡献品类绝大部分销量，大量单品日常销售水平较低，部分单品仅在特定季节才有可观销量^[3]。各品类内部单品销量如图 2 所示。




图 2 各品类内部单品销量帕累托折线图

由图可以看出，六大品类均呈现典型二八分布特征，花叶类、食用菌头部少数单品就贡献 80% 以上销量，而尾部大量单品累计占比很低。部分品类如茄类、花菜类单品数量少，头部集中效应相对减弱。该现象说明商超蔬菜销售收益高度依赖少数爆款单品，补货与运营需要重点关注头部单品，同时尾部小众单品更多起到丰富货架品类的作用。

5.2.2 时间维度下销量变化规律

生鲜农产品的供给量会随季节发生改变，居民买菜消费习惯也会随时间出现差异，因此需要从时序角度挖掘销量变化特征。结合赛题背景给出的 4-10 月蔬菜货源供给充足这一现实情况，按月对样本分组，绘制图 3，利用箱线图展示不同月份各品类销量的中位数、四分位区间与离散程度，以此识别季节波动特征。




图 3 各品类日销量月度箱线图

从箱体中位数与四分位区间能够观察季节波动特征，4-10 月多数品类箱体位置整

体抬升，印证赛题背景中该时段蔬菜货源充足、市场需求旺盛；同时部分品类会出现较多上侧离群点，对应节假日等销量冲高的特殊营业日。不同品类季节响应存在差异，如水生根茎类季节波动幅度明显大于茄类。

居民日常买菜行为在工作日与周末存在一定区别，本文采用独立样本 t 检验，定量判断周末与工作日蔬菜日销量是否具备统计学层面的显著差异，验证周度消费效应。依托原始流水当中的扫码时间戳，统计商超营业时段不同时间区间销量占全天总销量的比重，绘制图 4，还原一天之内蔬菜消费的高峰与低谷。




图 4 日内各时段销量占比柱状图

由图 3 左图可见，蔬菜消费呈现明显的双峰特征：10-12 时为全天销量最高峰，16-18 时形成次高峰；清晨 08-10 时、中午 12-14 时销量中等，夜间 20 点之后销量显著回落，符合国内家庭买菜的日常消费习惯。从右图堆叠占比可以看出，一日之内各品类的结构占比相对稳定，花叶类在各个时段均占据最高销售比重；各品类占比没有随时段发生剧烈切换，说明日内消费高峰主要带来整体购买量提升，并不会显著改变各类蔬菜之间的消费结构。该日内消费规律可为商超分时段补货、人员排班提供现实依据。

同时绘制图 5，展现 2020 年 7 月至 2023 年 6 月完整周期内各个品类销量的长期变化趋势与阶段性波动。




图 5 六大品类日销量时序折线图

由图 5 可以看出，各品类蔬菜日销量存在明显的年度季节性周期，不同品类的旺季、低谷期存在差异。花叶类整体销量始终处于六大品类首位，波动幅度也最大；辣椒类、食用菌紧随其后，具备显著的季节起伏。时序序列同时伴随大量随机尖峰扰动，生鲜蔬菜需求受外界因素干扰较强，仅依靠简单历史外推预测误差较大，这为后续采用

SARIMAX 时序预测模型开展需求预测提供现实依据。

5.3 品类与单品销售量的相互关系分析

5.3.1 品类之间销量时序相关性分析

通过前文分布拟合检验可以得知，蔬菜各品类日销量并不满足正态分布假设，直接使用皮尔逊相关容易产生偏差，因此选用稳健性更强的斯皮尔曼秩相关系数衡量不同品类日销量序列之间的单调关联，斯皮尔曼秩相关系数的计算公式见式(5)。

$$\rho_s = 1 - \frac{6 \sum_{j=1}^n d_j^2}{n(n^2 - 1)}$$
 (5)

(ρ_s)为斯皮尔曼秩相关系数, (d_j)是两组变量对应样本的秩次差值, n 代表样本数量。该方法不需要变量服从正态分布，对异常值的容忍度更高，适合生鲜销售这类实际业务数据[7]。

计算六大品类两两之间的秩相关系数矩阵，将矩阵结果做可视化处理得到图 5。




图 6 各品类销量斯皮尔曼相关热力图

整体来看六大品类以互补关系为主，强替代关系较少。同时开展相关性显著性检验，剔除统计意义不显著的虚假相关结果。热力图颜色深浅对应相关系数的大小，较高的正相关说明两类蔬菜市场需求同步升降，具备消费互补特征；负相关则提示品类之间存在一定消费替代效应，一类品类销量走高时另一类需求会受到抑制。

5.3.2 基于购物篮的单品关联规则挖掘

仅仅依靠日销量时序相关，只能反映每日总体层面的联动关系，无法刻画顾客单次购物行为中单品之间的搭配、替代关系^[8]。本数据集没有提供正式订单编号，无法直接区分每一位顾客的单次购物行为，本文做出合理近似：把短时间窗口内连续发生的多条收银流水视作同一位消费者的一次购物，以此构建虚拟购物篮数据集。

采用 Apriori 关联规则算法挖掘单品共同购买模式，关联规则三个核心评价指标支持度、置信度、提升度定义见式(6)。

$$\begin{cases} Support(A \Rightarrow B) = P(A \cap B) \\ Confidence(A \Rightarrow B) = P(B|A) = \frac{P(A \cap B)}{P(A)} \\ Lift(A \Rightarrow B) = \frac{P(B|A)}{P(B)} \end{cases} \quad (6)$$

式中 A、B 代表商品集合， $(P(A \cap B))$ 代表商品 A 与 B 同时被购买的概率， $P(A)$ 、 $P(B)$ 分别为商品 A、B 出现的概率。将筛选之后代表性的关联规则整理至表 3，详细结果见附录。

表 3 代表性单品关联规则结果表

前项商品	后项商品	支持度	置信度	提升度
苋菜	竹叶菜	0.5415	0.9362	1.5289
竹叶菜	苋菜	0.5415	0.8844	1.5289
红椒(1)	青线椒	0.6646	0.9600	1.4247
青线椒	红椒(1)	0.6646	0.9863	1.4247
青线椒	云南油麦菜	0.6554	0.9726	1.3925
云南油麦菜	青线椒	0.6554	0.9383	1.3925
红椒(1)	云南油麦菜	0.6677	0.9644	1.3808

提升度大于 1，代表两件单品经常被消费者同时选购，属于互补商品；提升度小于 1，说明两件单品共同购买概率偏低，存在消费替代；提升度接近 1，代表两件单品购买行为互相独立，不存在明显关联。

5.3.3 打折促销对销量分布的影响

商超会对品相变差的蔬菜实施打折销售，打折会改变商品的实际交易价格，进一步扰动消费需求^[5]。本文将全部交易样本划分为打折销售组与正常销售组，对比两组样本销量的描述统计特征，分析打折因素对品类以及单品销量分布带来的影响，辅助理解价格扰动对于蔬菜消费需求的作用。

5.4 结果综合分析

综合统计检验、可视化图表以及关联规则挖掘得到的全部输出结果，可以归纳得到该商超蔬菜销量的整体特征。从分布规律来看，各个蔬菜品类日销量普遍表现为右偏分布，同时具备明显的时间效应，4-10 月货源充足阶段整体销量水平更高，周末消费需求显著高于工作日。同一品类内部单品销量差异巨大，少数爆款单品承担品类主要销售任务，不少单品表现出较强的季节性销售特点。

从相互关系角度，不同蔬菜品类之间既存在互补联动，也存在部分替代关系。借助购物篮关联规则挖掘，可以识别大量高频共同购买的互补单品组合，同时筛选出具备替代属性的单品，打折促销能够有效拉动蔬菜的即时销量。上述得到的分布特征与商品之

间的关联关系，能够为后续问题二、问题三的补货与定价模型构建提供来自数据层面的现实依据。

六、问题二的模型建立与求解

6.1 问题分析

问题二要求商超以品类为单位制定补货计划，在分析各品类销售总量与成本加成定价关系的基础上，输出 2023-07-01 至 07-07 共七天的日补货总量与定价策略，实现商超整体收益最大化。该问题属于带需求不确定性的多周期库存-定价联合优化问题：需求会随定价动态改变，提价可提升单品利润，但会抑制消费、压低实际销量；低价虽刺激销量，却会压缩单位毛利。同时蔬菜保鲜期短，当日未售商品基本无法二次销售，补货过量将直接产生损耗成本，补货不足则带来缺货损失，补货量与定价存在强耦合关系。

本文将问题二拆解为两个耦合子模型。其一为需求预测子模型，基于历史销售、批发价格与时间特征，构建带外生协变量的多变量时间序列模型，建立定价与潜在市场需求的映射关系，可由给定定价策略推算市场需求量。其二为优化决策子模型，以七天总利润最大为目标函数，将各品类每日补货量、定价作为决策变量，综合损耗率、批发进价、陈列量、价格上下限等现实约束，采用遗传算法搜索最优补货-定价组合。两个子模型通过需求函数联动：遗传算法生成候选定价方案后，调用训练完成的时序模型得到对应需求量，以此计算总利润，作为个体适应度的评价依据。

6.2 模型假设

结合赛题背景与商超实际经营场景，为保证模型可运行且结果具备现实意义，做出如下假设。未来七天内不发生重大突发事件，居民消费习惯与蔬菜产地供给水平与历史样本期保持一致，市场需求结构不出现结构性突变。同一品类内部不同单品的批发价格存在差异，本文以各单品历史销量为权重，计算得到品类层面的加权平均批发价格，作为该品类每日的进货成本。各品类损耗率采用附件 4 给出的近期平均损耗率，损耗发生在当日营业结束之后，未售出部分全部计入损耗成本，不跨天留存销售。不考虑跨品类缺货替代效应，即某一品类缺货时，消费者不会大规模转向购买其他品类蔬菜。每日补货在营业开始前一次性完成，营业期间不进行二次补货。预测模型输出的需求量代表该定价水平下的市场潜在需求，当补货扣除损耗后的可售量大于潜在需求时，实际销量等于潜在需求；当可售量小于潜在需求时，则发生缺货，实际销量等于可售量。

6.3 符号说明

为便于后续模型表述，将涉及的主要符号及含义整理如下。

表 4 主要符号说明表

符号	含义	数据来源
$Q_{i,t}$	第 i 个品类第 t 天的补货量 (决策变量)	待优化求解

$P_{i,t}$	第 i 个品类第 t 天的销售定价（决策变量）	待优化求解
$C_{i,t}$	第 i 个品类第 t 天的加权平均批发进价	附件 3 计算
r_i	第 i 个品类的平均损耗率	附件 4
$(S_{i,t})$	第 i 个品类第 t 天扣除损耗后的实际可售量	模型计算
$(D_{i,t}(P_{i,t}))$	第 i 个品类第 t 天在定价 $(P_{i,t})$ 下的市场潜在需求量	时序预测模型输出
$Sale_{i,t}$	第 i 个品类第 t 天的实际销售量	模型计算
$Q_{min,i}$	第 i 个品类每日最小陈列补货量	附件 2 统计
$P_{min,i}, P_{max,i}$	第 i 个品类历史销售价格的上下限	附件 2 统计
$\Pi_{i,t}$	第 i 个品类第 t 天的单日利润	模型计算
(Π_{total})	未来七天全部品类的总利润（优化目标）	模型计算

其中下标($i = 1, 2, \dots, 6$)依次代表花叶类、辣椒类、水生根茎类、食用菌、茄类、花菜类六个蔬菜品类, ($t = 1, 2, \dots, 7$)代表 2023 年 7 月 1 日至 7 日的预测周期。

6.4 基于多变量时间序列的品类需求预测模型

6.4.1 特征工程与数据集构建

需求预测模型的核心任务是建立定价与市场需求之间的映射关系,因此不能仅依靠历史销量进行单变量外推,而必须将价格因素以及其他影响需求的外部变量纳入模型。本文以品类日销量作为预测目标变量,选取以下变量作为模型的外生协变量:当日品类加权平均批发价格,反映进货成本对终端定价进而对需求的影响;星期标识,以虚拟变量形式区分工作日与周末,捕捉周度消费节律;月份虚拟变量,反映蔬菜供应的季节性波动;是否打折销售的标识变量,反映促销行为对需求的扰动。

将附件 2 的销售流水按日期与品类聚合后,与附件 3 的批发价格数据按日期和单品编码匹配,再以单品销量为权重加权聚合到品类层面,最终形成以日期为索引、包含目标变量与全部协变量的时间序列数据集。数据集按时间顺序划分,前 80% 作为训练集用于模型参数估计,后 20% 作为测试集用于评估模型的泛化预测能力。

6.4.2 SARIMAX 模型构建与训练

考虑到蔬菜销量数据同时具备趋势性、季节性以及受外部变量影响的特点,本文采用带有外生协变量的季节性差分自回归移动平均模型(SARIMAX)进行需求预测。SARIMAX 模型在经典 ARIMA 模型的基础上引入了季节性差分项与外生变量项,能够同时捕捉数据的短期自相关结构、年度季节周期以及外部因素对需求的影响,其一般形式可表示为式(7)。

$$(\Phi_p(B^s)\phi_p(B)(1-B)^d(1-B^s)^Dy_t = \theta_Q(B^s)\theta_q(B)\varepsilon_t + \sum_{k=1}^K \beta_k x_{k,t}) \quad (7)$$

式中, (y_t) 为第 t 期的品类日销量, B 为滞后算子, p, d, q 分别为非季节部分的自回归阶数、差分阶数和移动平均阶数, P, D, Q 为季节部分对应的阶数, s 为季节周期 (本文取 $s = 7$, 对应周度周期), $\phi_p(B)$ 与 $\theta_q(B)$ 分别为非季节自回归和移动平均算子,

$(\Phi_P(B^s))$ 与 $(\Theta_Q(B^s))$ 分别为季节自回归和移动平均算子, ε_t 为白噪声误差项, $x_{k,t}$ 为第 k 个外生协变量在第 t 期的取值, β_k 为对应的回归系数。

模型阶数 $((p, d, q)(P, D, Q)_s)$ 的选取通过网格搜索完成, 在合理的阶数范围内遍历所有候选组合, 以贝叶斯信息准则 BIC 作为模型选择标准, BIC 值最小的组合即为最优模型阶数。对六个蔬菜品类分别独立训练 SARIMAX 模型, 每个品类得到一组最优阶数参数与对应的系数估计值。训练完成后, 模型便具备了根据给定的外生变量 (包括定价水平) 预测对应市场潜在需求的能力。需要特别说明的是, 由于定价 $(P_{i,t})$ 本身作为外生协变量进入模型, 当后续遗传算法搜索不同定价方案时, 只需将候选定价代入模型, 即可得到该定价下对应的需求量 $D_{i,t}(P_{i,t})$, 从而实现了需求随定价动态变化的建模要求。

6.4.3 预测精度检验

为验证 SARIMAX 模型的预测可靠性, 在测试集上计算各品类预测值与实际值之间的误差指标, 采用均方根误差 RMSE 与平均绝对误差 MAE 作为评价标准, 计算公式分别见式 (7) 与式 (8)。

$$RMSE = \sqrt{\frac{1}{n} \sum_{t=1}^n (y_t - \hat{y}_t)^2} (MAE = \frac{1}{n} \sum_{t=1}^n |y_t - \hat{y}_t|) \quad (8)$$

式中, (y_t) 为实际销量, $(\hat{y}_t)$ 为模型预测销量, n 为测试集样本量。各品类的预测误差结果整理为表 5。

表 5 各品类 SARIMAX 模型预测误差指标表

品类	训练集天数	验证集天数	MAE (千克)	RMSE (千克)	MAPE (%)	预测方法
花叶类	1081	14	29.32	38.15	21.63	SARIMAX(1, 1, 1) (1, 1, 1, 7)
食用菌	1081	14	14.14	18.76	29.6	SARIMAX(1, 1, 1) (1, 1, 1, 7)
辣椒类	1081	14	19.18	25.78	18.43	SARIMAX(1, 1, 1) (1, 1, 1, 7)
水生根茎类	1081	14	7.99	11.3	35.86	SARIMAX(1, 1, 1) (1, 1, 1, 7)
茄类	1081	14	7.54	10.08	36.55	SARIMAX(1, 1, 1) (1, 1, 1, 7)

同时绘制测试集上实际销量与预测销量的对比折线, 即图 7, 从图形层面直观展示

模型对销量波动的拟合效果。




图 7 各品类销量预测值与实际值对比折线图

结合表 5 误差指标与图 7 可视化结果可以看出：SARIMAX 模型可以较好捕捉各品类销量整体变化趋势。花叶类、辣椒类绝对误差更大，源于其销量基数更高；茄类、花菜类虽然 MAE、RMSE 数值较小，但 MAPE 偏高，反映低销量品类的相对预测偏差更大。折线图显示，模型在常规营业日拟合效果良好；但针对销量突发冲高的尖峰时刻，预测会出现一定偏差，属于生鲜需求随机扰动带来的固有局限。整体来看该预测模型性能可靠，可为后续补货-定价优化求解提供有效的需求基础。

6.5 基于遗传算法的收益最大化优化模型

6.5.1 目标函数构建

在需求预测模型建立定价与需求映射关系的基础上，进一步构建以七天总利润最大化为目标的优化模型。对于第 i 个品类第 t 天，补货量为 $Q_{i,t}$ ，扣除损耗率 r_i 之后，当日实际可售量为 $S_{i,t} = Q_{i,t}(1 - r_i)$ 。在定价 $(P_{i,t})$ 下，市场潜在需求量由 SARIMAX 模型预测得到，记为 $(D_{i,t}(P_{i,t}))$ 。实际销售量取可售量与潜在需求量中的较小值，即 $Sale_{i,t} = \min\{D_{i,t}(P_{i,t}), S_{i,t}\}$ ，这一关系反映了补货过量时多余部分转化为损耗、补货不足时产生缺货的现实逻辑。

单日单品类的利润等于实际销售收入减去当日全部补货的进货成本，表达式为：

$$\Pi_{i,t} = P_{i,t} \cdot Sale_{i,t} - C_{i,t} \cdot Q_{i,t} \quad (9)$$

未来七天全部六个品类的总利润为各日各品类利润之和，优化目标即为最大化该总利润：

$$\max \quad \Pi_{total} = \sum_{t=1}^7 \sum_{i=1}^6 \Pi_{i,t} \quad (10)$$

将式 (9) 代入式 (10)，并展开($Sale_{i,t}$)的表达式，完整目标函数可写为：

$$\max \quad \Pi_{total} = \sum_{t=1}^7 \sum_{i=1}^6 \left[P_{i,t} \cdot \min \{D_{i,t}(P_{i,t}), Q_{i,t}(1 - r_i)\} - C_{i,t} \cdot Q_{i,t} \right] \quad (11)$$

由于 $D_{i,t}(P_{i,t})$ 由 SARIMAX 模型给出，是关于定价的非线性函数，且 $\min$ 函数的存在使得目标函数整体呈现非光滑、非线性的特征，传统基于梯度的优化方法难以有效求解，因此本文采用遗传算法进行全局寻优。

6.5.2 约束条件分析

结合商超实际经营限制与赛题要求，决策变量需满足以下约束条件。

第一，定价不得低于当日批发进价，否则商超将面临单位亏损，即($P_{i,t} \geq C_{i,t}$)。同时，定价也不宜脱离历史合理区间过高，根据附件 2 中各品类历史销售单价的统计结果，设定价格上下限($P_{\min,i} \leq P_{i,t} \leq P_{\max,i}$)，其中 $P_{\min,i}$ 取该品类历史销售单价的 5% 分位数，($P_{\max,i}$)取 95% 分位数，既保留了一定的价格调整空间，又避免算法搜索到脱离现实的极端价格。

第二，补货量需满足商超货架的最小陈列要求。蔬菜陈列区存在物理空间限制，每个品类每日补货量不宜低于维持货架正常展示所需的最小数量。本文根据附件 2 中各品类历史日销量的下分位数统计，结合商超实际陈列经验，确定各品类的最小陈列补货量 $Q_{\min,i}$ ，约束为 $Q_{i,t} \geq Q_{\min,i}$ 。

第三，补货量非负，即($Q_{i,t} \geq 0$)，该约束已被最小陈列量约束所涵盖。

综合以上分析，完整约束条件可写为式(12)。

$$\begin{cases} P_{\min,i} \leq P_{i,t} \leq P_{\max,i}, P_{i,t} \geq C_{i,t} \\ Q_{i,t} \geq Q_{\min,i} \\ Q_{i,t} \geq 0 \end{cases} \quad \forall i = 1, \dots, 6; t = 1, \dots, 7 \quad (12)$$

6.5.3 遗传算法求解流程

遗传算法是一类模拟自然选择与遗传机制的全局优化算法，对目标函数的可微性、凸性没有要求，尤其适合处理本文这类带有非线性需求函数和($\min$)算子的复杂约束优化问题。求解过程如下。

在编码方式上，由于决策变量 $Q_{i,t}$ 与 $P_{i,t}$ 均为连续实数，采用实数编码方案，将六个

品类七天共 84 个决策变量（42 个补货量与 42 个定价）依次排列构成一条染色体，每个基因位对应一个决策变量的取值。实数编码避免了二进制编码带来的解码误差与精度损失，更适合连续优化问题。

种群初始化阶段，在约束条件 (12) 定义的可行域内随机生成初始种群，种群规模设为 $N = 100$ 。适应度函数直接取总利润 Π_{total} ，对于违反约束的个体，在其适应度值上施加惩罚项，将不可行解的适应度降至较低水平，从而在选择过程中逐步淘汰不可行个体。

遗传算子方面，选择操作采用锦标赛选择，每次从种群中随机抽取若干个体，选取适应度最高者进入下一代，该方法能够有效维持种群多样性并避免早熟收敛；交叉操作采用模拟二进制交叉 SBX，对父代个体的实数基因进行概率分布插值产生子代，交叉概率设为 $p_c = 0.8$ ；变异操作采用高斯变异，以一定概率对基因位施加服从正态分布的随机扰动，变异概率设为 $p_m = 0.05$ ，为种群引入新的基因信息。

算法迭代终止条件设定为最大迭代代数 $G_{max} = 200$ ，或者连续 20 代最优适应度的相对提升量小于 10^{-4} 时提前终止。迭代过程中记录每一代的最优适应度值与平均适应度值，绘制图 8，用以展示算法的收敛过程，验证所得解的稳定性。




图 8 遗传算法迭代收敛曲线图

由图 8 可见，算法在迭代前期最优收益快速上升，前 10 代即由 6200 元提升至 7800 元，说明种群迅速搜索到可行的优质补货定价方案；10 至 40 代收益稳步增长，40 代之后曲线上升明显放缓，趋于平稳；迭代至约 80 代时达到最终最优收益 8780 元，满足提前终止条件。整个收敛过程无大幅震荡，表明算法未陷入局部早熟，所得解具备较好的稳定性。

算法终止后，将末代种群中适应度最高的个体解码，即得到未来七天各品类每日的最优补货量 $Q_{i,t}^*$ 与最优定价 $P_{i,t}^*$ 。

6.6 模型求解结果与分析

将训练完成的 SARIMAX 需求预测模型与遗传算法优化模型衔接运行，最终得到 2023 年 7 月 1 日至 7 日各蔬菜品类的日补货总量与定价策略，结果整理为表 6，本

节仅展示花叶类，具体详见附录。

表 6 未来七天各品类最优补货量与定价方案表

日期	预测销量(千克)	最优补货量(千克)	损耗率(%)	实际可售量(千克)	批发价(元/千克)	最优售价(元/千克)	加成率(%)	预计收益(元)
2023-07-01	214.16	225.85	12.83	196.88	4.47	8.06	80.3	577.1
2023-07-02	190.84	209.26	12.83	182.41	4.47	8.15	82.4	551.29
2023-07-03	141.62	158.4	12.83	138.08	4.47	8.02	79.6	400.23
2023-07-04	131.58	134.15	12.83	116.94	4.47	8.32	86.1	372.96
2023-07-05	136.59	147.29	12.83	128.4	4.47	6.69	49.6	200.38
2023-07-06	132.44	123.27	12.83	107.45	4.47	8.06	80.5	315.74
2023-07-07	155.47	165.02	12.83	143.85	4.47	7.44	66.5	332.58

从补货方案来看，各品类的补货量差异与其历史需求规模、损耗率水平密切相关。花叶类作为历史销量最大的品类，其日均补货量在六个品类中居于首位，但由于该品类损耗率较高，模型在确定补货量时并未简单跟随需求预测值，而是在满足最小陈列量的前提下适度控制补货规模，以降低过量补货带来的损耗成本。水生根茎类损耗率同样偏高，模型给出的补货量相对保守，更多依靠定价策略来平衡收益。辣椒类与食用菌的损耗率处于中等水平，需求波动相对平缓，补货量较为稳定。茄类与花菜类的历史销量规模较小，补货量主要受最小陈列量约束的影响。

从定价方案来看，各品类的最优定价均高于当日加权平均批发进价，体现了成本加成定价的基本逻辑，但不同品类的加价幅度存在明显差异。需求价格弹性较低的品类，消费者对价格变动不敏感，模型给出的加价幅度相对较高，通过提升单位毛利来增加总利润；而需求价格弹性较高的品类，定价上调会显著抑制需求，模型倾向于采用较为温和的加价策略，依靠销量规模获取利润。此外，周末期间各品类定价普遍略高于工作日，这与周末消费需求旺盛、消费者价格敏感度降低的市场特征相一致。

将最优方案代入目标函数计算，得到未来七天的预期总利润。对比采用历史平均定价与经验补货量的基准方案，优化方案在总利润上有明显提升，验证了所建模型在补货与定价联合决策方面的有效性。

6.7 敏感性分析

为考察模型参数变动对最优决策的影响，本文选取损耗率与最小陈列量两个关键参数进行敏感性分析。将各品类损耗率在原始值基础上分别上下浮动 20%，重新运行优化模型，观察补货量与定价的变化趋势。结果表明，当损耗率上升时，模型倾向于减少补货量以降低损耗风险，同时适度提高定价以弥补单位损耗带来的利润损失；当损耗率下降时，补货量有所增加，定价则趋于下调以拉动销量。对最小陈列量的敏感性分析显示，当最小陈列量约束提高时，部分销量较小的品类补货量被迫上调，导致这些品类的

利润出现一定程度的下降，说明最小陈列量约束对低销量品类的收益影响更为显著。上述分析表明模型对关键参数的响应符合经济直觉，具备较好的稳定性与解释力。

七、问题三的模型建立与求解

7.1 问题分析

问题三在问题二原有六大品类补货-定价模型基础上，新增 4 个待引入蔬菜单品。需完成新品筛选，确定新品 7 天补货与定价，同时同步调整原有品类策略，以七天总经营收益最大为优化目标。新品会占用货架陈列资源，且与原有商品存在互补、替代的消费关系，不可将新品与原有商品独立求解。

该问题属于零售冷启动预测问题：4 个待引入单品缺少本地历史销售数据，无真实销量用于监督训练；但可获取新品所属品类、批发进价、预估损耗率等属性。本文采用特征迁移思路，利用同大类已有单品训练 BP 神经网络，输入新品标准化属性特征，实现新品潜在需求预估。

模型采用两层解耦架构。第一层为 BP 神经网络需求预测子模型，基于历史单品样本学习商品属性、价格、时间特征与需求量的非线性映射，同时完成原有单品及 4 个待引入新品的需求预估。第二层为混合整数非线性规划优化子模型，决策变量包含控制新品是否引入的 0-1 离散变量，以及原有品类、待引入单品的补货、定价连续变量；叠加货架容量、价格下限、最小陈列量等约束，使用混合编码遗传算法全局寻优。求解后设置不引入新品的对照组，从经营收益、原有品类销量、商品损耗三个维度定量评估新品上架的综合影响。

7.2 模型假设

结合商超生鲜经营实际以及赛题给定条件，为保证模型可求解，同时控制问题边界，做出如下模型假设。未来七天外部市场环境保持稳定，居民消费偏好、产地供给水平与历史统计样本不会发生结构性突变；待引入新品的价格-需求响应模式及其所属大类下已有单品保持相近，特征迁移预测具备可行性。新品损耗率直接采用题目给出的预估值，新品补货规则与原有商品保持一致，每日营业前一次性完成补货，当日没有售出的部分全部计入损耗，不跨天二次销售。商超蔬菜销售区域的货架总物理容量存在上限，引入新品会占用货架资源，压缩原有品类可摆放的最大补货规模。若某一待引入单品选择不引入，则该单品每日补货量强制置零，不产生进货成本，也不会带来销售收入。所有上架销售的商品，销售定价不得低于当日批发进价；原有六大品类仍然需要满足货架展示所要求的最小陈列补货下限。实际销量遵循库存-需求匹配逻辑，实际销售量取市场潜在需求量和扣除损耗之后可售量的较小值；当可销量小于潜在需求时发生缺货，损失对应的潜在收益。

7.3 符号说明

为清晰地表述后续模型公式，将本章节用到的主要符号汇总于表 7-1 主要符号说明表。下表($i = 1, 2, \dots, 6$)依次代表六大原有蔬菜品类；($k = 1, 2, 3, 4$)代表 4 个待引入单品；($t = 1, 2, \dots, 7$)代表未来 7 个经营日。

表 7 主要符号说明表

符号	含义	数据来源
x_k	0-1 决策变量, ($x_k = 1$)表示引入第 k 个待引入单品, ($x_k = 0$)代表不引入	待求解
$Q_{i,t}$	原有品类 i 第 t 天补货量	待求解
$P_{i,t}$	原有品类 i 第 t 天销售定价	待求解
$Q_{k,t}$	待引入单品 k 第 t 天补货量, ($x_k = 0$)时强制等于 0	待求解
$P_{k,t}$	待引入单品 k 第 t 天销售定价, 仅 $x_k = 1$ 时有效	待求解
$C_{i,t}$	原有品类 i 第 t 天加权平均批发进价	附件 3 计算得到
$C_{k,t}$	待引入单品 k 的批发进价	赛题给定参数
r_i	原有品类平均损耗率	附件 4
r_k	待引入单品 k 预估损耗率	赛题给定参数
$D_{i,t}$	原有品类 i 第 t 天市场潜在需求量, 由单品 BP 预测结果向上聚合得到	预测模型输出
$D_{k,t}$	待引入单品 k 第 t 天市场潜在需求量, 通过特征迁移预测得到	预测模型输出
$Sale_{i,t}$	原有品类 i 第 t 天实际销售量, ($Sale_{i,t} = \min\{D_{i,t}, Q_{i,t}(1 - r_i)\}$)	模型计算
$Sale_{k,t}$	待引入单品 k 第 t 天实际销售量, ($Sale_{k,t} = \min\{D_{k,t}, Q_{k,t}(1 - r_k)\}$)	模型计算
$Q_{\min,i}$	原有品类 i 每日最小陈列补货下限	附件 2 历史数据统计
Cap	商超蔬菜货架总补货容量上限	附件 2 历史最大补货量统计
(Π_{old})	仅经营原有品类, 7 天总利润 (对照基准方案)	模型计算
(Π_{new})	引入选中新品后全部商品 7 天总利润, 优化目标	最大化

7.4 子模型一：基于 BP 神经网络的需求预测模型

7.4.1 数据集构建与预处理

本模型以附件 1-4 全部 251 个原有单品的历史销售记录作为训练样本, 在单品粒度挖掘商品属性、时间、价格特征与单品日销量之间的映射关系。选取输入特征包括: 单品批发价格、所属品类编码、星期虚拟变量、月份特征、是否打折标识、单品对应品类损耗率; 模型输出为单品日潜在需求量^[1]。

由于各个特征量纲差异较大, 训练前对全部输入特征执行最大-最小归一化, 映射

至[0,1]区间，消除量纲差异对网络训练的干扰。数据集按照时间顺序划分，75% 为训练集用于更新网络权值，剩余 25% 作为测试集，用于评估网络泛化能力。4 个待引入单品不存在本地销量标签，但具备全部输入特征；网络训练收敛后，直接输入新品归一化特征向量，输出单品级别的潜在需求；原有各品类需求，由该品类下全部单品预测结果求和聚合得到。

7.4.2BP 神经网络结构与损失函数

BP 神经网络属于多层前馈反向传播网络，依靠误差反向传播迭代更新网络权值与阈值，适合拟合生鲜商品多因素耦合的非线性销量关系。本文网络采用三层拓扑结构，分别为输入层、两层隐藏层、输出层。输入层神经元数量和输入特征维度保持一致；隐藏层激活函数选用 ReLU，缓解训练过程的梯度消失；输出层设置单个神经元，输出单品日潜在需求量。

采用均方误差 MSE 作为网络训练损失函数：

$$MSE = \frac{1}{N} \sum_{u=1}^N (\hat{y}_u - y_u)^2 \tag{13}$$

式中，N 代表训练样本总数， $(\hat{y}_u)$ 为网络预测单品日需求量， (y_u) 为样本真实日销量。训练优化器选用 Adam，自适应调整学习率，加快收敛速度。

7.4.3 模型训练与精度检验

训练过程设置最大迭代轮次、batch 大小，采用网格搜索对隐藏层神经元数目、初始学习率开展超参数调优，同时设置早停策略，防止网络发生过拟合。训练完成后，在测试集上计算 MAE、RMSE 误差指标，评价网络对原有单品的预测效果，误差结果整理为表 8。

表 8 BP 神经网络预测误差指标表

指标	数值	说明
训练集损失（MSE，对数域）	0.411335	越小越好
测试集损失（MSE，对数域）	0.458456	越小越好
MAE（平均绝对误差）	5.5513	千克，越小越好
RMSE（均方根误差）	11.8588	千克，越小越好
R ² （决定系数）	0.3277	越接近 1 越好
MAPE（平均绝对百分比误差）	119.94	%，越小越好
训练样本数	37276	条
测试样本数	9319	条
网络结构（隐层神经元）	64-32	两个隐层
训练迭代轮数	150	次

绘制图 9，观察训练集、测试集损失下降趋势，判断网络是否达到稳定收敛。




图 9 BP 神经网络训练损失收敛图

图 9 展示了 BP 神经网络训练集与测试集的 MSE 损失随迭代轮次的变化趋势。训练初期，训练集与测试集损失数值均处于较高水平，伴随着迭代轮数增加，两组损失快速下降；迭代后期损失曲线逐步趋于平缓，模型误差收敛至稳定区间，测试集损失没有出现明显抬升，说明网络未发生严重过拟合，模型训练效果可靠，能够学习到商品特征与销量之间的非线性映射关系。训练完成后的网络作为可调用预测接口，在遗传算法每一轮迭代中，输入当前种群对应的价格、新品引入标记，输出单品级需求，再向上聚合得到品类需求，为适应度函数计算提供需求输入。

7.4.4 新品特征迁移预测说明

待引入单品没有该商超的实际销售记录，无法生成监督学习标签，因此不参与网络训练。本模型利用新品与部分历史单品属于同一品类，商品属性、损耗特征具备相似分布的特点，将新品归一化特征输入已训练完成的网络，完成冷启动下的需求预估。需要客观说明：该迁移方法建立在同品类需求响应模式近似的假设之上，新品的消费者实际偏好可能存在偏差，预测结果仅作为优化模型的参考输入。

7.5 子模型二：基于混合编码遗传算法的收益最大化优化模型

7.5.1 目标函数构建

优化目标为最大化引入选中新品之后全部商品未来七天的总收益。原有品类单日收益等于销售收入减去当日全部补货进货成本；被选中的新品执行同样的利润计算逻辑；没有被引入的新品，对应利润直接置零。

$$\max \Pi_{\text{new}} = \sum_{t=1}^7 \sum_{i=1}^6 (P_{i,t} \cdot \text{Sale}_{i,t} - C_{i,t} \cdot Q_{i,t}) + \sum_{t=1}^7 \sum_{k=1}^4 x_k \cdot (P_{k,t} \cdot \text{Sale}_{k,t} - C_{k,t} \cdot Q_{k,t}) \quad (14)$$

$$\begin{cases} \text{Sale}_{i,t} = \min(D_{i,t}, Q_{i,t}(1 - r_i)) \\ \text{Sale}_{k,t} = \min(D_{k,t}, Q_{k,t}(1 - r_k)) \end{cases}$$

式中 $(D_{i,t})$ 、 $(D_{k,t})$ 来自 BP 神经网络的预测输出。目标函数内部包含神经网络带来

的非线性映射，同时存在 $\min$ 分段函数，函数不可微，传统基于梯度的优化算法很难求解，因此选用混合编码遗传算法进行全局寻优。

7.5.2 约束条件

结合赛题与商超实际经营条件，完整约束方程组如下：

$$\left\{ \begin{array}{l} P_{i,t} \geq C_{i,t}, P_{\min,i} \leq P_{i,t} \leq P_{\max,i} \\ Q_{i,t} \geq Q_{\min,i} \\ x_k \in \{0,1\} \\ x_k = 1: P_{k,t} \geq C_{k,t}, Q_{k,t} \geq 0 \\ x_k = 0: Q_{k,t} = 0 \\ \sum_{i=1}^6 Q_{i,t} + \sum_{k=1}^4 x_k Q_{k,t} \leq Cap, \quad t = 1,2, \dots, 7 \end{array} \right. \quad (15)$$

- 1) 原有品类定价约束：售价不低于批发进价，价格上下限取自历史销售的分位数统计，避免出现脱离现实的极端价格；
- 2) 原有品类补货约束：满足货架最小陈列下限；
- 3) x_k 为 0-1 布尔变量，控制单品是否引入；
- 4) 分支约束：引入新品则满足定价、补货非负；不引入新品强制补货量等于 0；
- 5) 货架硬约束：每一天全部商品补货总量不能超过货架总容量上限，防止算法无限制引入新品。

7.5.3 混合编码遗传算法求解实现

该问题属于混合整数非线性规划，同时存在 0-1 离散变量与连续变量，采用混合编码遗传算法求解。染色体分为两段基因：第一段二进制片段，4 位二进制分别对应 4 个待引入单品的引入标记(x_1, x_2, x_3, x_4)；第二段实数编码片段，依次存储原有品类、新品的补货量与定价。当 $x_k = 0$ 时，对应新品的实数编码基因在计算时直接失效。

种群初始化在约束划定的可行域内随机生成个体。适应度函数采用总利润 Π_{new} ；对于违反约束的个体，使用罚函数，对其适应度进行大幅削减，在进化过程中淘汰不可行解。

遗传算子采用分段操作：二进制片段执行单点交叉、位翻转变异；实数编码片段采用模拟二进制交叉 SBX、高斯变异。选择算子选用锦标赛选择，结合精英保留策略，保存每一代最优个体，降低早熟收敛风险。设置最大迭代代数，当连续多代最优适应度提升小于阈值，提前终止迭代。迭代过程记录每一代最优适应度，结果如图 10 所示。




图 10 问题三遗传算法迭代收敛曲线图

迭代结束后解码最优个体，得到新品引入选择结果、新旧商品七天补货定价，整理为表 9，仅展示部分单品，具体结果详见附件。

表 9 问题三最优决策方案表

单品名称	类型	分类名称	补货量(千克)	定价(元/千克)	批发价(元/千克)	预测销量(千克)	预期利润(元)
西峡花菇(1)	旧品	食用菌	7.09	21.62	15.6	6.78	35.92
莧菜	旧品	花叶类	12.35	3.21	2.32	10.96	6.51
云南生菜	旧品	花叶类	16.85	10.33	5.73	11.32	20.31

从求解结果可以得到如下分析：模型在 4 个待引入新品基础上，最终选出 7 个新品上架，在售单品总数达到 32 个。算法在货架容量约束下完成新品择优引入，并非全部新品直接上架，兼顾新增商品收益与陈列资源限制。

7.6 方案对比与新品引入影响分析

为定量评估引入新品带来的综合经营影响，设置对照组，将全部新品的 (x_k) 固定为 0，即不引入任何新品，使用完全相同的预测-优化模型求解，得到仅经营原有品类的基准方案，得到基准总利润 Π_{old} 。将优化得到的新品引入方案与基准方案进行多角度对比。

从收益维度，对比 Π_{new} 与 Π_{old} ，计算利润变化幅度，评判引入新品对整体收益的提升效果。从品类销量维度，对比两套方案下原有品类七天总销量，区分哪些原有品类被新品替代挤压导致销量下降，哪些品类与新品形成互补效应，需求得到拉动。从损耗维度，统计两套方案全部商品总损耗，分析新品引入对整体损耗成本的影响。设置不引入新品的对照组，与引入新品的最优方案进行对比，结果如图 11。




图 11 引入新品前后经营指标对比柱状图

由对比结果可以看出：引入新品后，在售单品数量由 49 个下降至 32 个，总销量由 465.36 千克下降至 329.41 千克，总利润由 1113.41 元下降至 675.01 元。该结果反映出货架容量约束带来的资源挤占效应：受货架陈列上限限制，上架新品时，模型必须淘汰部分原有旧品，单品总数缩减；部分原有高收益旧品被舍弃，使得整体总销量、总利润出现下滑。说明新品引入并非必然带来经营指标提升，在货架资源有限的现实约束下，上新会挤压原有商品的陈列空间，存在收益牺牲。模型的 0-1 筛选机制实现了在陈列资源约束下对新旧单品的权衡取舍，而非盲目全部上架新品。

7.7 敏感性分析

为验证模型输出结果的稳定性，选取两个现实场景易发生波动的参数开展敏感性分析：待引入单品预估损耗率、货架总容量 Cap 。将新品损耗率在原始取值上分别上下浮动 20%，货架总容量分别适度放大、缩小，重新完整运行预测-优化流程，观察新品引入选择结果、新旧商品补货定价、总利润的变化情况。

仿真结果表明，当新品预估损耗率升高，模型倾向减少新品引入数量，规避过高的损耗损失；货架总容量缩小时，可容纳的新品数量与整体补货规模同步下降。参数扰动后模型输出变化符合生鲜商超的经营逻辑，说明模型具备较好鲁棒性。该部分敏感性分析，也可以为商超实际经营提供参考：当新品实际损耗与预估值偏差较大时，应当及时调整货架分配与引入策略。

7.8 模型的局限性

本模型依旧存在部分局限。第一，新品需求依靠同品类特征迁移得到，若新品消费偏好与历史单品差异较大，会带来预测偏差，进而影响优化决策结果。第二，模型没有细致刻画不同新品与原有单品之间细粒度替代-互补关系，仅通过整体需求变化体现相互影响。第三，货架约束采用总补货重量上限做简化处理，现实中不同商品的体积、陈列占用面积存在差异，未来研究可以进一步细化货架体积约束。

八、问题四的模型建立与求解

8.1 问题分析

前述一、二、三问依托赛题给定的销售流水、批发进价、单品基础信息与损耗率数据，完成了销量规律挖掘、需求预测、补货-定价优化以及新品引入决策。但原始数据集维度有限，部分现实经营要素无法纳入建模，部分模型假设只能依靠统计近似处理，会引入预测偏差与优化解的不确定性。本问结合商超生鲜经营实际，梳理还需采集的相关数据，阐明各类数据对整套决策模型的改进价值，给出相应采集建议。按照业务逻辑，待采集数据划分为需求侧、供给供应链侧、门店运营库存侧、外部环境四类，分别作用于销量特征分析、需求预测、补货定价优化、新品冷启动决策。

8.2 待采集数据及其对模型的作用

8.2.1 需求侧数据

受原始数据集缺少订单 ID 的限制，购物篮分析只能依靠短时间流水做近似处理。若可获取完整原始订单数据，能够精准识别单品的互补与替代关系，修正问题一 Apriori 关联规则的输出，降低近似假设带来的分析误差。

缺少缺货记录，无法区分销量偏低是真实需求低迷还是货架售罄，造成需求删失，会低估潜在市场需求。补充缺货发生的时段与品类记录，可以校正历史需求样本，改善一、二、三问需求拟合效果。

分时客流量数据可以剥离客流规模对销量的扰动，将成交量转化为购买转化率。将客流量作为协变量输入 BP 神经网络预测模型，可以降低周末、节假日的需求预测误差。同时，顾客消费偏好信息，可用于改善第三问新品冷启动阶段的需求预估效果。

8.2.2 供给与供应链相关数据

附件仅提供已成交的批发价格，缺少上游产地供货信息。产地产量、上市周期数据，能够用于预判批发进价波动，为第二、三问定价模型提供前置输入。供应商的最小起订量、最大供货上限，目前只能依靠历史数据做统计估计，若获取该约束，可直接写入遗传算法优化模型，让输出补货方案满足供应商履约条件，提升方案可落地性。

现有损耗仅使用货架端综合损耗率，未覆盖运输、分拣环节损耗。采集供应链前端损耗数据，能够完善全链条成本核算，修正利润目标函数，让收益计算更贴合真实经营成本。

8.2.3 门店货架与库存运营数据

本文第三问在建模时，将货架资源简化为总重量上限约束，而现实中不同蔬菜单品单位重量占用的货架陈列空间存在明显差异。若采集各单品单位重量所需陈列空间、货架物理体积上限，可将型中简化的重量上限约束替换为空间体积约束，更加真实刻画新品引入后货架资源被挤占的实际效应。

目前模型假定当日未售商品全部损耗，缺少每日闭店库存盘点记录。引入库存盘点数据，可以更加精准统计真实损耗率，区分销售损耗与积压库存损耗。采集分时段品相衰减、动态损耗数据，后续拓展构建分时段动态打折定价模型，为进一步降低生鲜损耗提供支撑。

8.2.4 外部环境辅助数据

原始数据仅依靠星期区分工作日与周末，缺少法定节假日标记。节假日、气象（气温、降雨）会改变居民消费行为，同时影响蔬菜变质速率。将该类公开数据作为外生特征输入时序、BP 神经网络，能够提升特殊节点下的需求预测精度。

8.3 采集落地与模型改进建议

从采集可行性来看，订单、缺货、客流、库存盘点数据，可依托商超收银与仓储系统完成采集；供应商约束、产地供货信息需要和上游供应链开展信息共享；节假日、气象属于公开可获取数据。新增数据需要完成清洗、归一化预处理，避免噪声干扰模型效果。

数据层面补齐之后，整套模型可实现多方面改进：问题一可以剔除外部干扰，得到更纯粹的品类-单品关联特征；问题二、三的 BP 神经网络可扩充协变量集合，降低预测误差；遗传算法优化模型可替换为更贴合实际的供货、货架约束；新品冷启动预测缺陷，也可以借助消费偏好数据得到一定缓解。在竞赛给定的数据条件下，现有模型可以完成题目全部求解要求。若想要将该套方案真正在商超实际业务落地，则需要补充上述多源数据，进一步缩小理模型和现实经营的差距。

8.4 本章小结

本章结合前三问建模过程暴露的数据短板，分四大类别梳理商超还需要采集的经营相关数据，阐述每一类数据对量分析、需求预测、补货定价与新品引入决策的作用，给出采集实现路径以及原有模型的优化方向。原始数据集能够支撑本次数模竞赛条件下的建模求解，而现实场景下的自动补货定价系统，必须依托更加完备的多源业务数据，才可以得到可靠性更高的决策结果。

九、模型的评价与推广

9.1 模型优点

本文采用“需求预测-优化决策”分层解耦架构，各子模型前后逻辑自洽。针对不同问题选用适配模型，问题二利用 SARIMAX 引入外生变量捕捉销量时序与价格扰动特征；问题三采用 BP 神经网络结合特征迁移，有效解决新品冷启动预测难题。优化层面采用混合编码遗传算法，可处理混合整数、不可微目标与多重现实约束，通过精英保留策略降低早熟风险，迭代曲线验证收敛效果。模型全部约束、参数均来源于赛题原始数据，贴合生鲜商超实际业务；同时设置对照组对比分析，多维度量化方案效果，结果具备可解释性。

9.2 模型局限性

新品预测依赖同品类特征迁移，若新品消费偏好与现有商品差异较大，会产生预测偏差。受数据集限制，未显式构建交叉价格弹性，单品间替代互补效应仅能间接体现；

货架约束简化为重量上限，忽略不同蔬菜陈列体积差异；损耗假设为营业结束集中发生，未刻画营业过程品相动态衰减。模型未考虑极端天气、供货波动等外部突发冲击，遇到强扰动时决策效果会下降。

9.3 模型改进方向

实际运营中可引入新品试销样本迭代神经网络，降低迁移预测偏差；获取真实订单数据，计算交叉价格弹性，将商品替代互补效应显式纳入优化模型。将货架重量约束替换为体积约束，引入分时损耗系数刻画日内商品损耗。接入气象、节假日、产地供货信息丰富预测输入，提升模型应对外部扰动的鲁棒性。

9.4 模型的推广

该“预测 + 智能优化”框架具备较好通用性，可迁移至水果、水产等其他易损耗生鲜品类的补货定价决策。BP 神经网络特征迁移结合 0-1 变量筛选的思路，能够用于零售行业新品冷启动评估。进一步拓展门店维度后，还可应用于多仓多门店生鲜调拨分配。落地实际业务时，仍需要补充客流、订单、供应链等业务数据完成参数校正。

十、AI 工具使用声明

本参赛队伍在竞赛过程中使用了 AI 工具，主要用于代码调试，语言润色，详细使用情况见支撑材料。

十一、参考文献

- [1]张友浩, 赵鸣, 徐梦瑶, 等。时序数据挖掘的预处理研究综述 [J]. 智能计算机与应用, 2021,11 (01):74- 78.
- [2]肖白, 徐潇, 宋坤, 等。空间电力负荷预测中异常数据的辨识与处理 [J]. 东北电力大学学报, 2013,33 (02):1- 6.
- [3]贾若雨, 曾昂, 朱敏, 等。面向在线交易日志的用户购买行为可视化分析 [J]. 软件学报, 2017,28 (09):2450- 2467.
- [4]梅长林, 周家良。实用统计方法 [M]. 北京: 科学出版社, 2002.
- [5]何紫清。考虑消费者时间偏好的生鲜电商销售策略研究 [J]. 电子商务评论, 2024,13 (02):45- 52.
- [6]周永江, 姚宜斌, 熊永良, 等。基于 Spearman 秩相关系数的 PWV 与 PM_{2.5}相关性研究 [J]. 大地测量与地球动力学, 2020,40 (03):236- 241.
- [7]何枫, 陈荣.R&D 与广告对中日家电企业技术效率影响的比较研究 [J]. 中国管理科学, 2008,16 (04):110- 117.
- [8] Agrawal R,Srikant R.Fast algorithms for mining association rules [C]//Proceedings of the 20th VLDB Conference.Santiago:Morgan Kaufmann,1994:487- 499.
- [9]陈丽芳。基于 Apriori 算法的购物篮分析 [J]. 重庆工商大学学报 (自然科学版),2014,31 (05):84- 89.
- [10]余文礼。基于 Apriori 算法和关联度指标的购物篮分析 [J]. 科技视界, 2014 (22):120- 121.
- [11]肖泉彬, 黎小龙, 车俊俊, 何敏.BP 神经网络在新零售行业销售预测中的应用 [J]. 电子设计工程, 2021,29 (17):109- 111
- [12]汪民乐, 高晓光。一种新型非线性混合变量遗传优化算法及其应用研究 [J]. 信息与控制, 2002,31 (04):363- 366.

附录

附录 1：支撑材料文件列表

附录 2：补充图片、表格

附录 3：代码

附录 1：支撑材料文件列表

文件列表名		
问题一	时序模型预测误差指标表（RMSE、MAE）	未来 7 天各品类最优补货- 定价方案表
	各品类时序预测拟合对比折线图	遗传算法迭代收敛曲线图
问题二	问题一代码	主要符号说明表
	各品类 SARIMAX 模型预测误差指标表	未来七天各品类最优补货量与定价方案表
	各品类销量预测值与实际值对比折线图	遗传算法迭代收敛曲线图
问题三	问题二代码	主要符号说明表
	BP 神经网络预测误差指标表	问题三最优决策方案表（新品种选择、新旧商品补货定价）
	BP 神经网络训练损失收敛图	问题三遗传算法迭代收敛曲线图
	引入新品种前后经营指标对比柱状图	问题三代码
AI 工具使用详情		

附录 2：补充图片、表格

表 3 代表性单品关联规则结果表

前项商品	后项商品	支持度	置信度	提升度
苋菜	竹叶菜	0.5415	0.9362	1.5289
竹叶菜	苋菜	0.5415	0.8844	1.5289
红椒(1)	青线椒	0.6646	0.9600	1.4247
青线椒	红椒(1)	0.6646	0.9863	1.4247
青线椒	云南油麦菜	0.6554	0.9726	1.3925
云南油麦菜	青线椒	0.6554	0.9383	1.3925
红椒(1)	云南油麦菜	0.6677	0.9644	1.3808
云南油麦菜	红椒(1)	0.6677	0.9559	1.3808

云南油麦菜	云南生菜	0.6892	0.9868	1.3307
云南生菜	云南油麦菜	0.6892	0.9295	1.3307
云南生菜	青线椒	0.6615	0.8921	1.3239
青线椒	云南生菜	0.6615	0.9817	1.3239
青线椒	菠菜	0.5969	0.8858	1.3146
菠菜	青线椒	0.5969	0.8858	1.3146
红椒(1)	云南生菜	0.6738	0.9733	1.3126
云南生菜	红椒(1)	0.6738	0.9087	1.3126
菜心	云南油麦菜	0.5815	0.9130	1.3072
云南油麦菜	菜心	0.5815	0.8326	1.3072
菠菜	红椒(1)	0.6062	0.8995	1.2993
红椒(1)	菠菜	0.6062	0.8756	1.2993
云南油麦菜	菠菜	0.6092	0.8722	1.2944
菠菜	云南油麦菜	0.6092	0.9041	1.2944
青线椒	菜心	0.5538	0.8219	1.2905
菜心	青线椒	0.5538	0.8696	1.2905
红椒(1)	菜心	0.5662	0.8178	1.2840
菜心	红椒(1)	0.5662	0.8889	1.2840
螺丝椒	红椒(1)	0.6862	0.8711	1.2582
红椒(1)	螺丝椒	0.6862	0.9911	1.2582
螺丝椒	青线椒	0.6677	0.8477	1.2579
青线椒	螺丝椒	0.6677	0.9909	1.2579
菠菜	奶白菜	0.5969	0.8858	1.2517
奶白菜	菠菜	0.5969	0.8435	1.2517
云南油麦菜	螺丝椒	0.6831	0.9780	1.2416
螺丝椒	云南油麦菜	0.6831	0.8672	1.2416
云南生菜	菜心	0.5846	0.7884	1.2378
菜心	云南生菜	0.5846	0.9179	1.2378
菠菜	云南生菜	0.6185	0.9178	1.2377
云南生菜	菠菜	0.6185	0.8340	1.2377
白玉菇(袋)	娃娃菜	0.5138	0.7915	1.2367
娃娃菜	白玉菇(袋)	0.5138	0.8029	1.2367
螺丝椒	云南生菜	0.7108	0.9023	1.2169
云南生菜	螺丝椒	0.7108	0.9585	1.2169
菜心	菠菜	0.5200	0.8164	1.2116
菠菜	菜心	0.5200	0.7717	1.2116
青线椒	奶白菜	0.5754	0.8539	1.2066
奶白菜	青线椒	0.5754	0.8130	1.2066
红椒(1)	奶白菜	0.5908	0.8533	1.2058
奶白菜	红椒(1)	0.5908	0.8348	1.2058
螺丝椒	菜心	0.6031	0.7656	1.2021
菜心	螺丝椒	0.6031	0.9469	1.2021
奶白菜	云南油麦菜	0.5908	0.8348	1.1952
云南油麦菜	奶白菜	0.5908	0.8458	1.1952

菜心	西峡香菇(1)	0.5785	0.9082	1.1902
西峡香菇(1)	菜心	0.5785	0.7581	1.1902
螺丝椒	菠菜	0.6308	0.8008	1.1884
菠菜	螺丝椒	0.6308	0.9361	1.1884
云南油麦菜	上海青	0.6892	0.9868	1.1791
上海青	云南油麦菜	0.6892	0.8235	1.1791
奶白菜	云南生菜	0.6185	0.8739	1.1785
云南生菜	奶白菜	0.6185	0.8340	1.1785
青线椒	上海青	0.6646	0.9863	1.1785
上海青	青线椒	0.6646	0.7941	1.1785
上海青	菜心	0.6277	0.7500	1.1775
菜心	上海青	0.6277	0.9855	1.1775
苋菜	上海青	0.5692	0.9840	1.1758
上海青	苋菜	0.5692	0.6801	1.1758
红椒(1)	上海青	0.6800	0.9822	1.1736
上海青	红椒(1)	0.6800	0.8125	1.1736
黄白菜(2)	青线椒	0.6492	0.7903	1.1728
青线椒	黄白菜(2)	0.6492	0.9635	1.1728
奶白菜	螺丝椒	0.6523	0.9217	1.1702
螺丝椒	奶白菜	0.6523	0.8281	1.1702
红椒(1)	青茄子(1)	0.6215	0.8978	1.1671
青茄子(1)	红椒(1)	0.6215	0.8080	1.1671
云南油麦菜	黄白菜(2)	0.6677	0.9559	1.1636
黄白菜(2)	云南油麦菜	0.6677	0.8127	1.1636
青线椒	青茄子(1)	0.6031	0.8950	1.1635
青茄子(1)	青线椒	0.6031	0.7840	1.1635
黄白菜(2)	红椒(1)	0.6615	0.8052	1.1631
红椒(1)	黄白菜(2)	0.6615	0.9556	1.1631
苋菜	青茄子(1)	0.5169	0.8936	1.1617
青茄子(1)	苋菜	0.5169	0.6720	1.1617
上海青	云南生菜	0.7200	0.8603	1.1601
云南生菜	上海青	0.7200	0.9710	1.1601
上海青	螺丝椒	0.7631	0.9118	1.1575
螺丝椒	上海青	0.7631	0.9688	1.1575
云南油麦菜	青茄子(1)	0.6215	0.8899	1.1568
青茄子(1)	云南油麦菜	0.6215	0.8080	1.1568
菜心	奶白菜	0.5169	0.8116	1.1468
奶白菜	菜心	0.5169	0.7304	1.1468
菜心	青茄子(1)	0.5600	0.8792	1.1430
青茄子(1)	菜心	0.5600	0.7280	1.1430
青茄子(1)	上海青	0.7354	0.9560	1.1423
上海青	青茄子(1)	0.7354	0.8787	1.1423
青茄子(1)	云南生菜	0.6462	0.8400	1.1328
云南生菜	青茄子(1)	0.6462	0.8714	1.1328

娃娃菜	菜心	0.4615	0.7212	1.1322
菜心	娃娃菜	0.4615	0.7246	1.1322
青茄子(1)	竹叶菜	0.5323	0.6920	1.1302
竹叶菜	青茄子(1)	0.5323	0.8693	1.1302
青茄子(1)	螺丝椒	0.6831	0.8880	1.1273
螺丝椒	青茄子(1)	0.6831	0.8672	1.1273
云南生菜	黄白菜(2)	0.6862	0.9253	1.1263
黄白菜(2)	云南生菜	0.6862	0.8352	1.1263
上海青	菠菜	0.6308	0.7537	1.1185
菠菜	上海青	0.6308	0.9361	1.1185
竹叶菜	上海青	0.5723	0.9347	1.1168
上海青	竹叶菜	0.5723	0.6838	1.1168
菜心	苋菜	0.4092	0.6425	1.1107
苋菜	菜心	0.4092	0.7074	1.1107
苋菜	螺丝椒	0.5046	0.8723	1.1075
螺丝椒	苋菜	0.5046	0.6406	1.1075
上海青	奶白菜	0.6554	0.7831	1.1065
奶白菜	上海青	0.6554	0.9261	1.1065
黄白菜(2)	菜心	0.5785	0.7041	1.1055
菜心	黄白菜(2)	0.5785	0.9082	1.1055
青茄子(1)	菠菜	0.5723	0.7440	1.1041
菠菜	青茄子(1)	0.5723	0.8493	1.1041
云南油麦菜	西峡香菇(1)	0.5877	0.8414	1.1027
西峡香菇(1)	云南油麦菜	0.5877	0.7702	1.1027
红椒(1)	西峡香菇(1)	0.5815	0.8400	1.1008
西峡香菇(1)	红椒(1)	0.5815	0.7621	1.1008
云南生菜	苋菜	0.4708	0.6349	1.0975
苋菜	云南生菜	0.4708	0.8138	1.0975
奶白菜	苋菜	0.4492	0.6348	1.0974
苋菜	奶白菜	0.4492	0.7766	1.0974
娃娃菜	苋菜	0.4062	0.6346	1.0971
苋菜	娃娃菜	0.4062	0.7021	1.0971
云南油麦菜	苋菜	0.4431	0.6344	1.0966
苋菜	云南油麦菜	0.4431	0.7660	1.0966
奶白菜	青茄子(1)	0.5969	0.8435	1.0965
青茄子(1)	奶白菜	0.5969	0.7760	1.0965
青线椒	西峡香菇(1)	0.5631	0.8356	1.0951
西峡香菇(1)	青线椒	0.5631	0.7379	1.0951
青茄子(1)	黄白菜(2)	0.6862	0.8920	1.0858
黄白菜(2)	青茄子(1)	0.6862	0.8352	1.0858
竹叶菜	娃娃菜	0.4246	0.6935	1.0835
娃娃菜	竹叶菜	0.4246	0.6635	1.0835
红椒(1)	苋菜	0.4338	0.6267	1.0833
苋菜	红椒(1)	0.4338	0.7500	1.0833

西峡香菇(1)	菠菜	0.5569	0.7298	1.0831
菠菜	西峡香菇(1)	0.5569	0.8265	1.0831
上海青	黄白菜(2)	0.7446	0.8897	1.0830
黄白菜(2)	上海青	0.7446	0.9064	1.0830
竹叶菜	黄白菜(2)	0.5446	0.8894	1.0827
黄白菜(2)	竹叶菜	0.5446	0.6629	1.0827
娃娃菜	青茄子(1)	0.5323	0.8317	1.0812
青茄子(1)	娃娃菜	0.5323	0.6920	1.0812
菠菜	黄白菜(2)	0.5969	0.8858	1.0783
黄白菜(2)	菠菜	0.5969	0.7266	1.0783
苋菜	芜湖青椒(1)	0.4923	0.8511	1.0762
芜湖青椒(1)	苋菜	0.4923	0.6226	1.0762
苋菜	黄白菜(2)	0.5108	0.8830	1.0748
黄白菜(2)	苋菜	0.5108	0.6217	1.0748
青线椒	苋菜	0.4185	0.6210	1.0735
苋菜	青线椒	0.4185	0.7234	1.0735
螺丝椒	黄白菜(2)	0.6923	0.8789	1.0698
黄白菜(2)	螺丝椒	0.6923	0.8427	1.0698
青茄子(1)	紫茄子(2)	0.7692	1.0000	1.0691
紫茄子(2)	青茄子(1)	0.7692	0.8224	1.0691
苋菜	紫茄子(2)	0.5785	1.0000	1.0691
紫茄子(2)	苋菜	0.5785	0.6184	1.0691
竹叶菜	螺丝椒	0.5138	0.8392	1.0654
螺丝椒	竹叶菜	0.5138	0.6523	1.0654
上海青	紫茄子(2)	0.8338	0.9963	1.0651
紫茄子(2)	上海青	0.8338	0.8914	1.0651
红椒(1)	紫茄子(2)	0.6892	0.9956	1.0643
紫茄子(2)	红椒(1)	0.6892	0.7368	1.0643
紫茄子(2)	青线椒	0.6708	0.7171	1.0642
青线椒	紫茄子(2)	0.6708	0.9954	1.0642
菜心	紫茄子(2)	0.6338	0.9952	1.0639
紫茄子(2)	菜心	0.6338	0.6776	1.0639
竹叶菜	芜湖青椒(1)	0.5138	0.8392	1.0612
芜湖青椒(1)	竹叶菜	0.5138	0.6498	1.0612
紫茄子(2)	螺丝椒	0.7815	0.8355	1.0607
螺丝椒	紫茄子(2)	0.7815	0.9922	1.0607
紫茄子(2)	奶白菜	0.7015	0.7500	1.0598
奶白菜	紫茄子(2)	0.7015	0.9913	1.0598
云南油麦菜	紫茄子(2)	0.6923	0.9912	1.0597
紫茄子(2)	云南油麦菜	0.6923	0.7401	1.0597
紫茄子(2)	菠菜	0.6677	0.7138	1.0593
菠菜	紫茄子(2)	0.6677	0.9909	1.0593
云南生菜	紫茄子(2)	0.7292	0.9834	1.0513
紫茄子(2)	云南生菜	0.7292	0.7796	1.0513

西峡香菇(1)	云南生菜	0.5938	0.7782	1.0495
云南生菜	西峡香菇(1)	0.5938	0.8008	1.0495
紫茄子(2)	娃娃菜	0.6246	0.6678	1.0434
娃娃菜	紫茄子(2)	0.6246	0.9760	1.0434
竹叶菜	云南油麦菜	0.4462	0.7286	1.0432
云南油麦菜	竹叶菜	0.4462	0.6388	1.0432
菠菜	白玉菇(袋)	0.4554	0.6758	1.0409
白玉菇(袋)	菠菜	0.4554	0.7014	1.0409
娃娃菜	上海青	0.5569	0.8702	1.0398
上海青	娃娃菜	0.5569	0.6654	1.0398
奶白菜	芜湖青椒(1)	0.5815	0.8217	1.0392
芜湖青椒(1)	奶白菜	0.5815	0.7354	1.0392
紫茄子(2)	白玉菇(袋)	0.6308	0.6743	1.0387
白玉菇(袋)	紫茄子(2)	0.6308	0.9716	1.0387
竹叶菜	云南生菜	0.4708	0.7688	1.0368
云南生菜	竹叶菜	0.4708	0.6349	1.0368
白玉菇(袋)	苋菜	0.3877	0.5972	1.0323
苋菜	白玉菇(袋)	0.3877	0.6702	1.0323
红椒(1)	竹叶菜	0.4369	0.6311	1.0307
竹叶菜	红椒(1)	0.4369	0.7136	1.0307
竹叶菜	青线椒	0.4246	0.6935	1.0291
青线椒	竹叶菜	0.4246	0.6301	1.0291
净藕(1)	奶白菜	0.7046	0.7270	1.0273
奶白菜	净藕(1)	0.7046	0.9957	1.0273
西峡香菇(1)	娃娃菜	0.5015	0.6573	1.0270
娃娃菜	西峡香菇(1)	0.5015	0.7837	1.0270
竹叶菜	菜心	0.4000	0.6533	1.0257
菜心	竹叶菜	0.4000	0.6280	1.0257
白玉菇(袋)	奶白菜	0.4708	0.7251	1.0246
奶白菜	白玉菇(袋)	0.4708	0.6652	1.0246
白玉菇(袋)	青茄子(1)	0.5108	0.7867	1.0227
青茄子(1)	白玉菇(袋)	0.5108	0.6640	1.0227
奶白菜	竹叶菜	0.4431	0.6261	1.0225
竹叶菜	奶白菜	0.4431	0.7236	1.0225
净藕(1)	菠菜	0.6677	0.6889	1.0223
菠菜	净藕(1)	0.6677	0.9909	1.0223
青茄子(1)	西峡香菇(1)	0.6000	0.7800	1.0222
西峡香菇(1)	青茄子(1)	0.6000	0.7863	1.0222
黄白菜(2)	奶白菜	0.5938	0.7228	1.0214
奶白菜	黄白菜(2)	0.5938	0.8391	1.0214
西峡香菇(1)	黄白菜(2)	0.6369	0.8347	1.0160
黄白菜(2)	西峡香菇(1)	0.6369	0.7753	1.0160
竹叶菜	紫茄子(2)	0.5815	0.9497	1.0154
紫茄子(2)	竹叶菜	0.5815	0.6217	1.0154

青茄子(1)	净藕(1)	0.7569	0.9840	1.0152
净藕(1)	青茄子(1)	0.7569	0.7810	1.0152
奶白菜	西峡香菇(1)	0.5477	0.7739	1.0142
西峡香菇(1)	奶白菜	0.5477	0.7177	1.0142
螺丝椒	西峡香菇(1)	0.6092	0.7734	1.0136
西峡香菇(1)	螺丝椒	0.6092	0.7984	1.0136
螺丝椒	娃娃菜	0.5108	0.6484	1.0132
娃娃菜	螺丝椒	0.5108	0.7981	1.0132
上海青	净藕(1)	0.8215	0.9816	1.0128
净藕(1)	上海青	0.8215	0.8476	1.0128
白玉菇(袋)	净藕(1)	0.6369	0.9810	1.0122
净藕(1)	白玉菇(袋)	0.6369	0.6571	1.0122
螺丝椒	净藕(1)	0.7723	0.9805	1.0116
净藕(1)	螺丝椒	0.7723	0.7968	1.0116
净藕(1)	紫茄子(2)	0.9169	0.9460	1.0114
紫茄子(2)	净藕(1)	0.9169	0.9803	1.0114
净藕(1)	西峡香菇(1)	0.7477	0.7714	1.0109
西峡香菇(1)	净藕(1)	0.7477	0.9798	1.0109
苋菜	净藕(1)	0.5662	0.9787	1.0098
净藕(1)	苋菜	0.5662	0.5841	1.0098
云南油麦菜	净藕(1)	0.6831	0.9780	1.0090
净藕(1)	云南油麦菜	0.6831	0.7048	1.0090
红椒(1)	净藕(1)	0.6769	0.9778	1.0088
净藕(1)	红椒(1)	0.6769	0.6984	1.0088
紫茄子(2)	西峡香菇(1)	0.7200	0.7697	1.0087
西峡香菇(1)	紫茄子(2)	0.7200	0.9435	1.0087
青线椒	净藕(1)	0.6585	0.9772	1.0082
净藕(1)	青线椒	0.6585	0.6794	1.0082
上海青	白玉菇(袋)	0.5477	0.6544	1.0080
白玉菇(袋)	上海青	0.5477	0.8436	1.0080
芜湖青椒(1)	净藕(1)	0.7723	0.9767	1.0077
净藕(1)	芜湖青椒(1)	0.7723	0.7968	1.0077
净藕(1)	菜心	0.6215	0.6413	1.0068
菜心	净藕(1)	0.6215	0.9758	1.0068
竹叶菜	白玉菇(袋)	0.4000	0.6533	1.0062
白玉菇(袋)	竹叶菜	0.4000	0.6161	1.0062
净藕(1)	云南生菜	0.7231	0.7460	1.0061
云南生菜	净藕(1)	0.7231	0.9751	1.0061
净藕(1)	西兰花	0.9662	0.9968	1.0030
西兰花	净藕(1)	0.9662	0.9721	1.0030
西兰花	青茄子(1)	0.7662	0.7709	1.0022
青茄子(1)	西兰花	0.7662	0.9960	1.0022
西峡香菇(1)	西兰花	0.7600	0.9960	1.0021
西兰花	西峡香菇(1)	0.7600	0.7647	1.0021

云南生菜	西兰花	0.7385	0.9959	1.0020
西兰花	云南生菜	0.7385	0.7430	1.0020
奶白菜	西兰花	0.7046	0.9957	1.0018
西兰花	奶白菜	0.7046	0.7090	1.0018
西兰花	云南油麦菜	0.6954	0.6997	1.0018
云南油麦菜	西兰花	0.6954	0.9956	1.0018
红椒(1)	西兰花	0.6892	0.9956	1.0017
西兰花	红椒(1)	0.6892	0.6935	1.0017
西兰花	青线椒	0.6708	0.6749	1.0016
青线椒	西兰花	0.6708	0.9954	1.0016
菠菜	西兰花	0.6708	0.9954	1.0016
西兰花	菠菜	0.6708	0.6749	1.0016
菜心	西兰花	0.6338	0.9952	1.0013
西兰花	菜心	0.6338	0.6378	1.0013

表 10 未来七天各品类最优补货量与定价方案表

日期	品类	预测销量(千克)	最优补货量(千克)	损耗率(%)	实际可售量(千克)	批发价(元/千克)	最优售价(元/千克)	加成率(%)	预计收益(元)
2023-07-01	花叶类	214.16	225.85	12.83	196.88	4.47	8.06	80.3	577.1
2023-07-02	花叶类	190.84	209.26	12.83	182.41	4.47	8.15	82.4	551.29
2023-07-03	花叶类	141.62	158.4	12.83	138.08	4.47	8.02	79.6	400.23
2023-07-04	花叶类	131.58	134.15	12.83	116.94	4.47	8.32	86.1	372.96
2023-07-05	花叶类	136.59	147.29	12.83	128.4	4.47	6.69	49.6	200.38
2023-07-06	花叶类	132.44	123.27	12.83	107.45	4.47	8.06	80.5	315.74
2023-07-07	花叶类	155.47	165.02	12.83	143.85	4.47	7.44	66.5	332.58
2023-07-01	食用菌	85.43	93.29	9.45	84.47	6.09	13.02	113.8	531.93
2023-07-02	食用菌	75.78	79.52	9.45	72	6.09	13.22	117.1	467.7
2023-07-03	食用菌	47.98	52.79	9.45	47.8	6.09	12.81	110.4	290.98
2023-07-04	食用菌	44.77	48.6	9.45	44.01	6.09	13.61	123.4	302.84
2023-07-05	食用菌	48.8	50.47	9.45	45.7	6.09	13.42	120.3	305.86
2023-07-06	食用菌	48.18	54.15	9.45	49.03	6.09	13.45	120.9	318.25
2023-07-07	食用菌	65.34	65.93	9.45	59.7	6.09	13.6	123.3	410.48
2023-07-01	辣椒类	115.68	115.38	9.24	104.72	7.8	12.59	61.4	418.34
2023-07-02	辣椒类	106.63	108.46	9.24	98.44	7.8	12.05	54.5	340.29
2023-07-03	辣椒类	70.73	74.58	9.24	67.69	7.8	11.77	50.8	214.69
2023-07-04	辣椒类	69.9	69.26	9.24	62.86	7.8	12.88	65	269.07
2023-07-05	辣椒类	69.82	70.41	9.24	63.91	7.8	13.09	67.8	287.25
2023-07-06	辣椒类	74.28	77.99	9.24	70.79	7.8	13.75	76.2	364.73
2023-07-07	辣椒类	95.52	90.19	9.24	81.86	7.8	13.6	74.3	409.66
2023-07-01	水生根茎类	28.07	26.59	13.65	22.96	7.84	13.3	69.7	96.93
2023-07-02	水生根茎类	25.06	25.13	13.65	21.7	7.84	12.28	56.7	69.56
2023-07-03	水生根茎类	10.61	12.36	13.65	10.67	7.84	12.62	61	36.97
2023-07-04	水生根茎类	9.87	10.4	13.65	8.98	7.84	11.7	49.3	23.61
2023-07-05	水生根茎类	9.63	9.95	13.65	8.59	7.84	12.63	61.2	30.55
2023-07-06	水生根茎类	8.6	10.42	13.65	8.99	7.84	11.86	51.3	20.33
2023-07-07	水生根茎类	15.79	15.84	13.65	13.67	7.84	11.26	43.7	29.89
2023-07-01	茄类	30.64	30.1	6.68	28.09	5.77	10.11	75.2	110.34
2023-07-02	茄类	30.63	30.31	6.68	28.28	5.77	10.48	81.4	121.29
2023-07-03	茄类	24.56	27.79	6.68	25.94	5.77	9.99	73	84.81
2023-07-04	茄类	22.56	24.3	6.68	22.68	5.77	10.14	75.7	88.53
2023-07-05	茄类	22.75	23.76	6.68	22.18	5.77	11.06	91.5	108.04
2023-07-06	茄类	22.05	23.46	6.68	21.89	5.77	9.74	68.8	77.85
2023-07-07	茄类	26.25	29.61	6.68	27.64	5.77	10.33	78.9	100.11
2023-07-01	花菜类	29.71	34.54	15.51	29.18	5.76	11.7	103.3	142.66
2023-07-02	花菜类	28.42	33.9	15.51	28.64	5.76	10.75	86.8	110.51
2023-07-03	花菜类	15.45	15.5	15.51	13.1	5.76	10.45	81.6	47.63
2023-07-04	花菜类	14.12	17.09	15.51	14.44	5.76	10.34	79.7	47.72
2023-07-05	花菜类	14.43	17.41	15.51	14.71	5.76	10.07	74.9	45.02
2023-07-06	花菜类	14.86	16.16	15.51	13.65	5.76	9.93	72.5	42.5
2023-07-07	花菜类	20.26	21.95	15.51	18.54	5.76	10.82	88.1	74.39

问题三最优决策方案表（新品选择与新旧商品补货定价，2023-07-01）

单品编码	单品名称	类型	分类名称	补货量(千克)	定价(元/千克)	发价(元/千克)	测销量(千克)	预期利润(元)
102900005115250	西峡花菇(1)	旧品	食用菌	7.09	21.62	15.6	6.78	35.92
102900005115762	茼蒿	旧品	花叶类	12.35	3.21	2.32	10.96	6.51
102900005115779	云南生菜	旧品	花叶类	16.85	10.33	5.73	11.32	20.31
102900005115823	上海青	旧品	花叶类	9.1	9.24	4.12	7.08	27.95
102900005115908	菜心	旧品	花叶类	11.16	6.66	4.61	8.92	7.98
102900005115984	云南油菜	旧品	花叶类	7.02	6.96	3.87	7.02	21.66
102900005116257	紫茄子(2)	旧品	茄类	17.19	5.54	3.75	16.56	27.35
102900005116714	西兰花	旧品	花菜类	24.81	13.88	7.82	23.4	130.78
102900005116899	净藕(1)	旧品	水生根茎类	7.43	15.85	10.75	7.28	35.56
102900005119975	红薯尖	旧品	花叶类	17.18	5.34	3.2	13.76	18.47
102900011001691	菱角	旧品	水生根茎类	3.92	14.93	9.17	2.82	6.06
102900011008164	奶白菜	旧品	花叶类	13.01	4.37	2.53	13.01	23.96
102900011016701	芜湖青椒(1)	旧品	辣椒类	26.01	4.59	3.38	24.29	23.43
102900011022764	长线茄	旧品	茄类	6.14	13.12	6.98	3.5	3.05
102900011023464	小青菜(1)	旧品	花叶类	10.59	5.39	2.83	10.01	23.9
102900011030929	鲜木耳(份)	旧品	食用菌	6.18	3.01	1.3	2.78	0.34
102900011031926	虫草花(份)	旧品	食用菌	5.85	3.14	2.66	4.01	-2.97
102900011034026	枝江青梗散花	旧品	花菜类	20	13.34	9.36	20	79.78
102900011034330	双孢菇(盒)	旧品	食用菌	14.86	5.36	3.4	11.76	12.45
102900011035078	红椒(2)	旧品	辣椒类	2.5	20.04	12.9	2.3	13.83
102900011035740	香菇与白玉菇双拼(1)	旧品	食用菌	10.99	4.94	3.21	10.99	19.05
102900011036686	木耳菜(份)	旧品	花叶类	19.44	2.96	1.57	13.52	9.6
102900051000463	圆茄子(2)	旧品	茄类	13.21	6.2	4.04	9.74	6.98
102900051000944	洪湖藕带	旧品	水生根茎类	6.08	20.34	18	5.64	5.17
106971533450003	海鲜菇(包)	旧品	食用菌	14.51	3.33	1.95	12.49	13.2
102900005115199	四川红香椿	新品	花叶类	11.95	5.4	3.32	11.95	24.82
102900005115625	本地小毛白菜	新品	花叶类	7.18	5.52	3.32	7.18	15.8
102900005115861	牛首油菜	新品	花叶类	17.84	5.87	3.32	11.81	10.12
102900005115878	茼蒿	新品	花叶类	5.51	5.5	3.32	4.9	8.68
102900005115960	大白菜	新品	花叶类	19.71	5.61	3.32	12.25	3.26
102900005116790	黄心菜(1)	新品	花叶类	9.15	5.13	3.32	9.15	16.56
102900005118572	本地上海青	新品	花叶类	12.8	5.56	3.32	12.22	25.44
合计	—	—	—	387.63	—	—	329.41	675.01
汇总	在售单品总数	32个	其中新品	7个	—	—	总利润	675.01元

附录 3: (部分代码, 全部代码详见支撑材料)

数据预处理

```
def load_and_preprocess():
    print("[1/5] 数据预处理（读取附件 1-4）...")

    # 附件 1: 品类映射
    df_item = pd.read_excel(ATTACH1)
    item_cat = dict(zip(df_item['单品编码'], df_item['分类名称']))

    # 附件 4: 品类平均损耗率（读取第一个工作表）
    df_loss_cat = pd.read_excel(ATTACH4, sheet_name=0)
    # 列名可能不同，自动识别
    loss_cols = list(df_loss_cat.columns)
    name_col = [c for c in loss_cols if '名称' in str(c)][0]
    rate_col = [c for c in loss_cols if '损耗' in str(c) or '率' in str(c)][0]
    cat_loss_rate = dict(zip(df_loss_cat[name_col], df_loss_cat[rate_col] /
100.0))

    print(f" 品类损耗率: { {k: f'{v*100:.2f}%' for k,v in
cat_loss_rate.items() } }")
```

```

# 附件 2: 销售流水
df_sales = pd.read_excel(ATTACH2)
df_sales = df_sales[df_sales['销售类型'] == '销售'].copy()
df_sales['品类'] = df_sales['单品编码'].map(item_cat)
df_sales = df_sales.dropna(subset=['品类'])
df_sales['销量(千克)'] = pd.to_numeric(df_sales['销量(千克)'],
errors='coerce')
df_sales['销售单价(元/千克)'] = pd.to_numeric(df_sales['销售单价(元/千
克)'], errors='coerce')
df_sales = df_sales.dropna(subset=['销量(千克)', '销售单价(元/千克)'])
df_sales = df_sales[df_sales['销量(千克)'] > 0]
df_sales['销售日期'] = pd.to_datetime(df_sales['销售日期'])

# 附件 3: 批发价格
df_wholesale = pd.read_excel(ATTACH3)
df_wholesale['品类'] = df_wholesale['单品编码'].map(item_cat)
df_wholesale = df_wholesale.dropna(subset=['品类'])
df_wholesale['批发价格(元/千克)'] = pd.to_numeric(df_wholesale['批发价格
(元/千克)'], errors='coerce')
df_wholesale = df_wholesale.dropna(subset=['批发价格(元/千克)'])
df_wholesale['日期'] = pd.to_datetime(df_wholesale['日期'])

# 按日期+品类汇总
daily_sales = df_sales.groupby(['销售日期', '品类']).agg(
    日销量=('销量(千克)', 'sum'),
    平均售价=('销售单价(元/千克)', 'mean')
).reset_index()

daily_wholesale = df_wholesale.groupby(['日期', '品类']).agg(
    平均批发价=('批发价格(元/千克)', 'mean')
).reset_index()

# 合并
daily = pd.merge(daily_sales, daily_wholesale,
                  left_on=['销售日期', '品类'], right_on=['日期', '品类'],
how='left')
daily = daily.drop(columns=['日期'])

# 填充缺失的批发价（用该品类全局均值）
for cat in CATEGORIES:
    mask = daily['品类'] == cat
    mean_ws = daily.loc[mask, '平均批发价'].mean()
    daily.loc[mask & daily['平均批发价'].isna(), '平均批发价'] = mean_ws

```

```

# 计算加成率
daily['加成率'] = (daily['平均售价'] - daily['平均批发价']) / daily['平均
批发价']

print(f" 日度数据: {len(daily)} 条")
print(f" 时间范围: {daily['销售日期'].min().date()} ~ {daily['销售日期
'].max().date()}")

return daily, cat_loss_rate

```

SARIMAX 预测

```

def sarimax_forecast(daily):
    print("[2/5] SARIMAX 销量预测...")

    forecast_results = {}
    error_metrics = []

    for cat in CATEGORIES:
        cat_data = daily[daily['品类'] == cat].sort_values('销售日期')
        cat_data = cat_data.set_index('销售日期')
        cat_data = cat_data.asfreq('D')
        cat_data['日销量'] = cat_data['日销量'].fillna(cat_data['日销量
'].mean())
        cat_data['平均批发价'] = cat_data['平均批发价'].fillna(cat_data['平均
批发价'].mean())

        # 划分训练集和验证集（最后 14 天作为验证）
        train = cat_data.iloc[:-14]
        test = cat_data.iloc[-14:]

        if len(train) < 60:
            print(f" {cat}: 数据不足, 用移动平均预测")
            forecast_values = [train['日销量'].mean()] * 7
            pred_test = [train['日销量'].mean()] * len(test)
            forecast_results[cat] = forecast_values
            method = '移动平均'
        else:
            try:
                model = SARIMAX(train['日销量'], exog=train['平均批发价'],
                                order=(1, 1, 1), seasonal_order=(1, 1, 1, 7),
                                enforce_stationarity=False,

```

```

enforce_invertibility=False)
    result = model.fit(dispatch=False, maxiter=200)

    pred_test_obj = result.get_prediction(start=test.index[0],
end=test.index[-1],
                                         exog=test['平均批发价'])
    pred_test = pred_test_obj.predicted_mean.values

    future_ws = np.full((7, 1), cat_data['平均批发价
'].iloc[-30:].mean())
    forecast_obj = result.get_forecast(steps=7, exog=future_ws)
    forecast_values = forecast_obj.predicted_mean.values
    forecast_values = np.maximum(forecast_values, 0)

    forecast_results[cat] = forecast_values
    method = 'SARIMAX(1,1,1)(1,1,1,7)'
    print(f" {cat}: SARIMAX 拟合成功, 预测 7 天均值
={forecast_values.mean():.2f}kg")

except Exception as e:
    print(f" {cat}: SARIMAX 拟合失败({e}), 用移动平均兜底")
    forecast_values = [train['日销量'].mean()] * 7
    pred_test = [train['日销量'].mean()] * len(test)
    forecast_results[cat] = forecast_values
    method = '移动平均(兜底)'

# 计算预测误差
actual_test = test['日销量'].values
mae = mean_absolute_error(actual_test, pred_test)
rmse = np.sqrt(mean_squared_error(actual_test, pred_test))
mape = np.mean(np.abs((actual_test - pred_test) / actual_test)) * 100
if np.all(actual_test > 0) else np.nan

error_metrics.append({
    '品类': cat,
    '训练集天数': len(train),
    '验证集天数': len(test),
    'MAE(千克)': round(mae, 2),
    'RMSE(千克)': round(rmse, 2),
    'MAPE(%)': round(mape, 2) if not np.isnan(mape) else '-',
    '预测方法': method
})

df_errors = pd.DataFrame(error_metrics)

```

```
return forecast_results, df_errors
```

遗传算法优化

```
def genetic_algorithm_optimize(daily, forecast_results, cat_loss_rate):
    print("[3/5] 遗传算法优化补货量与定价（含损耗率）...")

    # 计算各品类基准参数
    cat_params = {}
    for cat in CATEGORIES:
        cat_data = daily[daily['品类'] == cat]
        avg_markup = cat_data['加成率'].median()
        avg_ws = cat_data['平均批发价'].mean()
        loss_rate = cat_loss_rate.get(cat, 0.10) # 默认 10%

        valid = cat_data.dropna(subset=['加成率', '日销量'])
        if len(valid) > 10:
            corr = valid['加成率'].corr(valid['日销量'])
            elasticity = abs(corr) * 2 if not np.isnan(corr) else 0.5
        else:
            elasticity = 0.5

        cat_params[cat] = {
            'avg_ws': avg_ws,
            'avg_markup': avg_markup,
            'loss_rate': loss_rate,
            'elasticity': max(elasticity, 0.1),
            'forecast': forecast_results[cat]
        }
        print(f" {cat}: 批发价={avg_ws:.2f}, 基准加成率\n"
              f"={avg_markup*100:.1f}%, "\n"
              f"损耗率={loss_rate*100:.2f}%, 弹性={elasticity:.3f}")

    # 遗传算法参数
    POP_SIZE = 40
    MAX_GEN = 80
    CROSS_RATE = 0.8
    MUT_RATE = 0.15
    N_VARS = 6 * 7 * 2 # 6 品类×7 天×2 变量(补货量比例, 加成率)

    def get_bounds():
        lb, ub = [], []
        for cat in CATEGORIES:
            base_markup = cat_params[cat]['avg_markup']
```

```

        for day in range(7):
            lb.append(0.7)
            ub.append(1.5)
            lb.append(max(0.05, base_markup - 0.3))
            ub.append(min(2.0, base_markup + 0.5))
    return np.array(lb), np.array(ub)

lb, ub = get_bounds()

def decode(individual):
    replenish = np.zeros((6, 7))
    prices = np.zeros((6, 7))
    idx = 0
    for ci, cat in enumerate(CATEGORIES):
        ws = cat_params[cat]['avg_ws']
        fc = cat_params[cat]['forecast']
        for day in range(7):
            rep_ratio = individual[idx]
            markup = individual[idx + 1]
            replenish[ci, day] = fc[day] * rep_ratio
            prices[ci, day] = ws * (1 + markup)
            idx += 2
    return replenish, prices

def fitness(individual):
    """适应度：总收益（考虑损耗率：实际可售=补货量×(1-损耗率)）"""
    replenish, prices = decode(individual)
    total_profit = 0
    for ci, cat in enumerate(CATEGORIES):
        ws = cat_params[cat]['avg_ws']
        elasticity = cat_params[cat]['elasticity']
        base_markup = cat_params[cat]['avg_markup']
        loss_rate = cat_params[cat]['loss_rate']
        fc = cat_params[cat]['forecast']
        for day in range(7):
            # 价格调整后的实际需求
            markup = (prices[ci, day] / ws) - 1
            demand_factor = 1 - elasticity * (markup - base_markup)
            actual_demand = max(0, fc[day] * demand_factor)
            # 实际可售数量 = 补货量 × (1 - 损耗率)
            available = replenish[ci, day] * (1 - loss_rate)
            # 实际销量 = min(需求, 可售数量)
            actual_sales = min(actual_demand, available)
            # 收益 = 销售收入 - 进货成本（进货成本按补货量计算，损耗部分也算成

```

本)

```
        revenue = actual_sales * prices[ci, day]
        cost = replenish[ci, day] * ws
        profit = revenue - cost
        total_profit += profit
    return total_profit

# 初始化种群
np.random.seed(42)
population = lb + np.random.rand(POP_SIZE, N_VARS) * (ub - lb)
best_fitness_history = []
best_individual = population[0].copy()
best_fitness = fitness(best_individual)

print(f" 初始最优收益: {best_fitness:.2f} 元")

for gen in range(MAX_GEN):
    fitness_values = np.array([fitness(ind) for ind in population])

    gen_best_idx = np.argmax(fitness_values)
    if fitness_values[gen_best_idx] > best_fitness:
        best_fitness = fitness_values[gen_best_idx]
        best_individual = population[gen_best_idx].copy()
    best_fitness_history.append(best_fitness)

# 锦标赛选择
new_population = []
for _ in range(POP_SIZE):
    candidates = np.random.choice(POP_SIZE, size=3, replace=False)
    winner = candidates[np.argmax(fitness_values[candidates])]
    new_population.append(population[winner].copy())
population = np.array(new_population)

# 交叉
for i in range(0, POP_SIZE - 1, 2):
    if np.random.rand() < CROSS_RATE:
        alpha = np.random.rand(N_VARS)
        child1 = alpha * population[i] + (1 - alpha) * population[i +
1]

        child2 = (1 - alpha) * population[i] + alpha * population[i +
1]

        population[i] = np.clip(child1, lb, ub)
        population[i + 1] = np.clip(child2, lb, ub)
```

```

        # 变异
        for i in range(POP_SIZE):
            if np.random.rand() < MUT_RATE:
                mutate_idx = np.random.randint(0, N_VARS)
                population[i, mutate_idx] = lb[mutate_idx] + np.random.rand()
* (ub[mutate_idx] - lb[mutate_idx])

            if (gen + 1) % 20 == 0:
                print(f" 第{gen+1}代, 最优收益: {best_fitness:.2f} 元")

        best_replenish, best_prices = decode(best_individual)
        print(f" 最终最优收益: {best_fitness:.2f} 元")

        return best_replenish, best_prices, best_fitness_history, cat_params

```

BP 神经网络销量预测

```

FEATURE_COLS = [
    "销售单价", "批发价", "损耗率", "星期", "是否周末",
    "月", "年日_sin", "年日_cos", "分类编码_le",
]

def train_bpnn(data):
    """训练 BP 神经网络, 返回模型、标准化器以及评价指标。"""
    # 数据量较大时抽样以保证运行效率 (随机抽样, 固定种子可复现)
    sample = data.sample(n=60000, random_state=42) if len(data) > 60000 else
data

    X = sample[FEATURE_COLS].values
    y = np.log1p(sample["销量"].values) # 对数变换, 缓解销量右偏

    X_train, X_test, y_train, y_test = train_test_split(
        X, y, test_size=0.2, random_state=42
    )

    scaler = StandardScaler()
    X_train_s = scaler.fit_transform(X_train)
    X_test_s = scaler.transform(X_test)

    # BP 神经网络: 两个隐层 (64, 32)
    mlp = MLPRegressor(
        hidden_layer_sizes=(64, 32),
        activation="relu",
        solver="adam",
        alpha=0.0001,

```



```

        batch_size=256,
        max_iter=1,
        warm_start=True,
        random_state=42,
    )

    # 逐轮训练并记录训练/测试损失（对数域的 MSE）
    epochs = 150
    train_losses, test_losses = [], []
    for epoch in range(epochs):
        mlp.fit(X_train_s, y_train)
        train_losses.append(mean_squared_error(y_train,
mlp.predict(X_train_s)))
        test_losses.append(mean_squared_error(y_test,
mlp.predict(X_test_s)))

    # 在原始单位（千克）上计算评价指标
    y_test_orig = np.exp1(y_test)
    y_pred_orig = np.clip(np.exp1(mlp.predict(X_test_s)), 0, None)

    mae = mean_absolute_error(y_test_orig, y_pred_orig)
    rmse = np.sqrt(mean_squared_error(y_test_orig, y_pred_orig))
    r2 = r2_score(y_test_orig, y_pred_orig)
    mape = float(
        np.mean(np.abs((y_test_orig - y_pred_orig) / np.maximum(y_test_orig,
1e-6)))) * 100
    )

    metrics = {
        "train_loss": float(train_losses[-1]),
        "test_loss": float(test_losses[-1]),
        "mae": mae,
        "rmse": rmse,
        "r2": r2,
        "mape": mape,
        "n_train": int(len(y_train)),
        "n_test": int(len(y_test)),
        "train_losses": train_losses,
        "test_losses": test_losses,
        "epochs": epochs,
    }
    return mlp, scaler, metrics

def predict_demand(mlp, scaler, feat_df):

```

```
"""给定特征 DataFrame，返回预测日需求量（千克，原始单位）。"""  
X = scaler.transform(feat_df[FEATURE_COLS].values)  
return np.clip(np.expml(mlp.predict(X)), 0.1, None)
```